汽车图文广告的自动化标签体系与可控生成方法研究——以特斯拉 Model Y 为例

摘 要

随着生成式人工智能技术的快速发展，传统汽车广告视觉物料生产长期受困于“高质量”与“低成本”、“短周期”难以兼顾的困境。特别是成套视觉资产的生成不仅需要保持车辆 ID 的精准识别，更需在多场景、多视角下实现宏观风格的高度统一。本研究以特斯拉 Model Y 为研究对象，提出了一种“数据洞察驱动+底层算法约束”的内容生产范式。

在数据工程层面，通过采集小红书平台 8,117 条帖文及 22,400 张原始图片，利用 TF-IDF 算法结合多模态大模型（CLIP、Qwen-VL）构建了“检索-标签-营销”三层映射框架与八大视觉标签体系，为生成式动态创意优化提供了标准化的自动化打标范式，并制作了包含 113 组多模态训练对的高质量数据集。在算法创新层面，针对现有扩散模型在多图生成任务中存在的“车辆 ID 漂移”与“宏观风格割裂”问题，对 FLUX 模型进行深度改进。首先，引入 In-Context LoRA（IC-LoRA）机制，通过 2×2 网格图像拼接与联合描述策略，激活 DiT 架构的全局上下文学习能力；其次，创新性地提出潜空间统计量对齐模块（LaSA），通过构建 Leader-Follower 机制在潜空间中直接约束宏观风格一致性；最后，设计基于扩散时间步的自适应衰减权重策略（Dynamic LaSA），化解了多任务学习中的梯度冲突。

实验结果表明，改进型 FLUX 模型在色彩一致性上较基线提升了 55.6%，综合评分提升 12.4%，且展现出较高的生成稳定性。本研究不仅为生成式 AI 在垂直商业领域的深度应用提供了重要的理论参考与工程实践，更为汽车广告乃至泛营销领域的视觉内容自动化生产开辟了全新路径，具有显著的学术价值与商业应用前景。相关代码已发布于 GitHub 平台：https://github.com/FRon17/LaSA.git.

关键词：FLUX；风格一致性；In-Context LoRA；潜空间对齐；

Research on Automated Tagging Systems and Controllable Generation Methods for Automotive Image-Text Advertisements: A Case Study of Tesla Model Y

ABSTRACT

With the rapid development of generative artificial intelligence technology, traditional automotive advertising visual content production has long been constrained by the dilemma of difficulty in balancing "high quality," "low cost," and "short production cycles." Particularly, the generation of visual asset suites requires not only precise vehicle ID recognition but also high macro-style consistency across multi-scenario and multi-perspective contexts. Taking Tesla Model Y as the research subject, this study proposes a content production paradigm of "data insight-driven + underlying algorithm constraints."

At the data level, by collecting 8,117 posts and 22,400 images from the Xiaohongshu platform and utilizing TF-IDF algorithm combined with multimodal models (CLIP, Qwen-VL), a three-layer mapping framework of "Retrieval-Tag-Marketing" and an eight-dimensional visual tag system was constructed, providing a standardized automated tagging paradigm for Generative Dynamic Creative Optimization (DCO), and generating 113 high-quality training dataset pairs. At the algorithmic level, addressing the issues of "vehicle ID drift" and "macro-style fragmentation" in existing diffusion models, the FLUX model was deeply improved: (1) introducing the In-Context LoRA mechanism to activate the global contextual learning capability of the DiT architecture through 2×2 grid concatenation; (2) innovatively proposing the Latent Statistical Alignment module (LaSA), which directly constrains macro-style consistency in latent space through a Leader-Follower mechanism; (3) designing an adaptive decay weighting strategy based on diffusion timesteps (Dynamic LaSA) to resolve gradient conflicts in multi-task learning.

Experimental results demonstrate that the improved model achieves a 55.6% improvement in color consistency compared to the baseline, with a 12.4% increase in comprehensive scores and significantly enhanced generation stability. This research provides important theoretical reference and engineering practice for the application of generative AI in vertical commercial domains, opening new pathways for automated production of automotive advertising visual content. Our code is publicly available at: https://github.com/FRon17/LaSA.git.

KEYWORDS: FLUX; Style Consistency; In-Context LoRA; Latent Space Alignment

目录

摘 要 I
ABSTRACT II
第一章 绪论 1
第一节 研究背景及意义 1
第二节 研究现状与挑战 2
第三节 研究内容与技术路线 2
第四节 论文组织结构 4
第二章 相关工作与理论基础 5
第一节 广告视觉生成的理论基础 5
第二节 扩散模型与 FLUX 架构演进 6
第三节 个性化微调技术 8
第四节 图像风格迁移与一致性控制 10
第五节 本章小结 12
第三章 汽车广告自动化视觉标签体系与数据工程 13
第一节 汽车社媒数据采集与清洗 13
第二节 基于 TF-IDF 的语义特征挖掘 15
第三节 多维视觉标签体系构建 17
第四节 面向 In-Context LoRA 的多模态广告数据集构建 18
第五节 本章小结 20
第四章 基于改进 FLUX 的广告图像可控生成方法 22
第一节 技术框架总览 22
第二节 基于 In-Context LoRA 的上下文学习 24
第三节 潜空间统计量对齐模块（LaSA） 25
第四节 基于扩散时间步的动态加权优化 29
第五节 本章小结 31
第五章 实验设置与结果分析 32

第一节 实验环境与配置 32
第二节 改进型 FLUX 模型生成效果定量分析 33
第三节 改进型 FLUX 模型生成效果定性分析 37
第四节 损失函数权重策略的消融探究 42
第五节 本章小结 44
第六章 总结与展望 46
第一节 研究总结 46
第二节 商业落地价值与行业赋能意义 47
第三节 局限性与未来展望 48
参考文献 50
致谢 53

第一章 绪论

第一节 研究背景及意义

技术变革营销，营销融入技术，技术与营销的共振从未停歇。随着人工智能技术的快速迭代与场景渗透，营销行业正迎来一次全面的范式革新，AI 已从营销辅助工具升级为核心驱动力，重构营销全链路的运作逻辑与价值创造方式。营销物料的生成与加工是生成式 AI（Generative AI）的重要应用场景[1]。然而，视觉物料的生产面临着“高质量且精准把控品牌调性”与“低成本”、“短制作周期”无法同时满足的困境。

传统的广告视觉物料主要依赖人工拍摄与后期设计，这种方式虽然能够精准传达品牌视觉资产与产品细节，但往往伴随着极高的资金成本和漫长的制作周期，难以适应现代数字营销快速迭代的节奏。生成式 AI 技术虽正在持续演进，亦须尊重广告、营销的基础法则。基础生成模型在实际商用中往往表现出极大的随机性，缺乏对特定商业逻辑和品牌视觉规范的深刻理解，导致生成的图像难以直接作为专业广告物料使用。因此，如何在保证品牌视觉资产安全的前提下，使用 AI 对创意素材生产降本提效，是当前营销领域的新痛点。

相较于快消品或 3C 数码产品，汽车广告的视觉呈现具有极高的特殊性与复杂性。汽车营销的视觉物料中车辆主体和场景是核心元素。汽车广告高度依赖于多场景、多视角的“成套”视觉资产展示[2]。在实际的营销战役（Campaign）中，单张图像的生成往往显得单薄，根本无法满足全方位展示产品卖点和构建品牌叙事的需求。传统营销资源的 AI 化虽然能够利用 AI 技术生成多模态素材以取代人工制作，但仍难以实现成套视觉资产在“车辆 ID”（如车灯结构）上符合真实产品细节，在“宏观风格（如整体光影色调）”上高度统一。因此，如何稳定、高效地生成成套且具有高度内在逻辑关联的汽车视觉资产，是当前汽车营销领域亟待解决的痛点。

针对上述痛点，本文以特斯拉 Model Y 为例[4]，提出了一种“数据洞察驱动+底层算法约束”的全新内容生产范式。本研究在数据端实现了从“社媒舆情挖掘”到“视

觉标签构建”的链路，在算法端通过改进 FLUX 模型的底层生成框架实现了多图排版的宏观风格强一致性，在保证品牌视觉资产一致性的前提下，为汽车广告图片制作的降本增效提供了切实可行的技术方案，为生成式 AI 在垂直商业领域的深度应用提供了重要的理论参考与工程实践。

第二节 研究现状与挑战

汽车广告作为一个高度专业化的垂直领域，其语言体系充斥着大量抽象的营销行业术语。诸如“极简科技”、“都市游牧”等概念性表达，虽然在广告从业者与目标消费者群体中具有明确的视觉指向，但对于基于互联网通用语料训练的基础大模型而言，这些词汇往往缺乏清晰的语义锚点。

传统的 T2I 模型（文本到图像生成模型）在面对这类高度抽象的提示词时，生成结果往往呈现出较大的随机性与不可预测性，难以准确还原广告策划者脑海中的具体视觉意象。这种语义可控性的缺失，本质上源于模型缺乏对特定领域知识的深度理解，是制约 AIGC 技术在垂直行业落地的关键瓶颈。

尽管 T2I 模型在单张图像的质量上已取得显著突破，但在多图联合生成任务中，视觉一致性控制仍然是学术界与产业界共同面临的核心难题。现有的 T2I 模型在生成多张图像时，难以保持“车辆 ID”层面的精确一致性。具体而言，即使使用相同的文本提示词，模型在不同批次的推理过程中生成的车辆往往会在车灯样式、车漆反光细节、车身比例等微观特征上出现随机变化，这使得生成的多张图像无法形成统一的产品认知。更为严峻的是“宏观风格”层面的一致性缺失。在实际生成中，即使车辆主体保持一致，不同图像之间仍可能出现光影分布、色彩基调、场景内在逻辑等方面的巨大差异，这种缺乏统一视觉语言的图像组合无法支撑品牌传播的连贯性需求[3]。

第三节 研究内容与技术路线

本研究围绕汽车图文广告的自动化标签体系构建与多图排版可控生成两大核心任务，提出了一套“数据洞察驱动+底层算法约束”的完整技术路线。整体技术路线如图 1. 1 所示，主要分为“基于社媒挖掘的标签体系构建”与“基于改进 FLUX 的可控生成”

两个关键阶段。在数据端，通过跨模态工程将抽象的营销诉求转化为结构化的视觉标签与多模态数据集；在算法端，通过引入上下文学习（In-Context LoRA）与潜空间统计量对齐机制（LaSA），从底层突破扩散模型在多图生成中的一致性瓶颈，最终实现符合商业规范的成套视觉资产自动化生产。

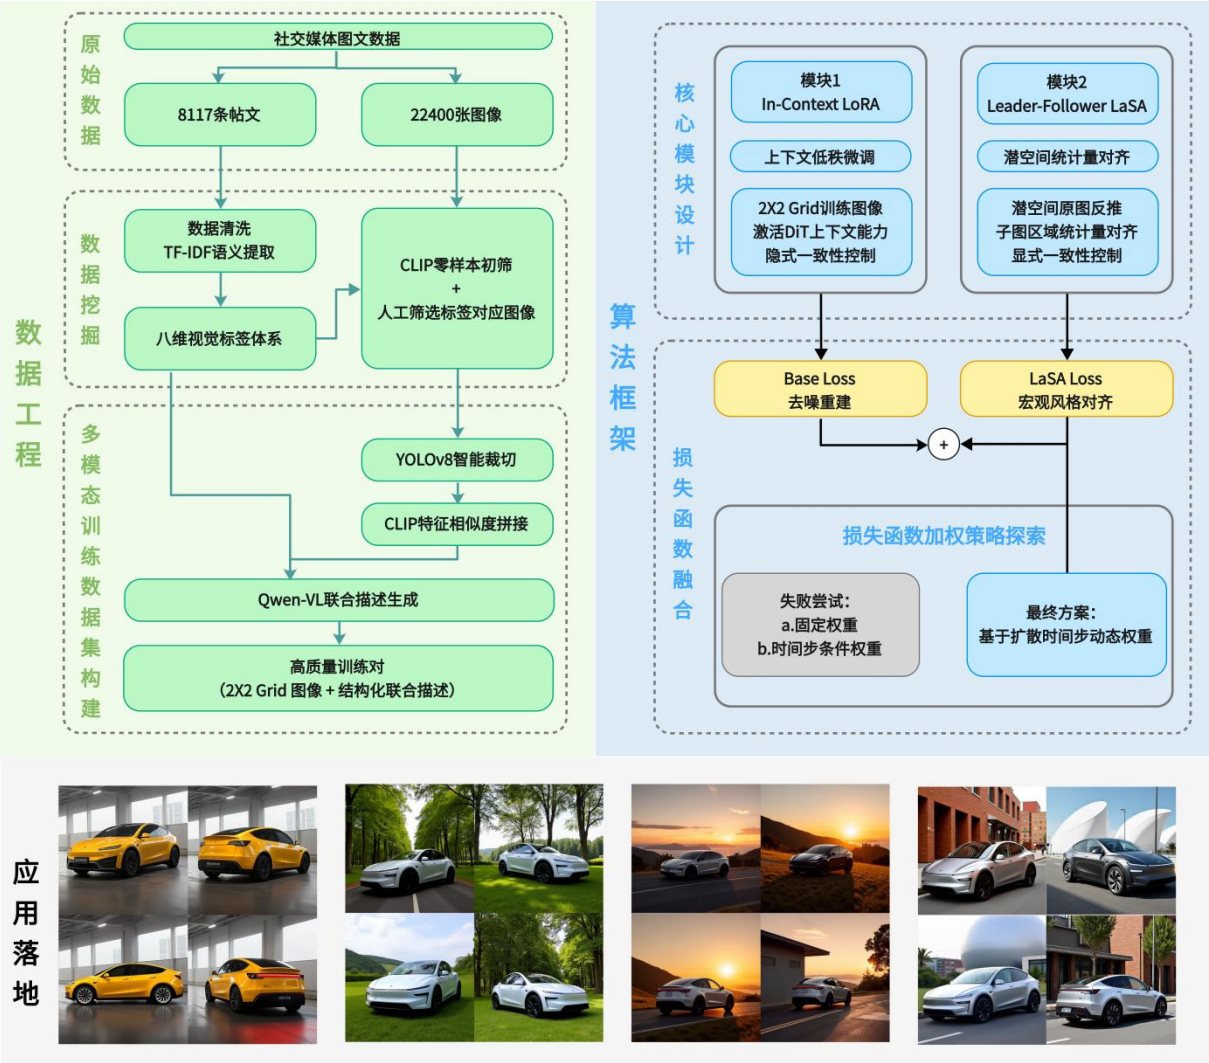

图 1.1 综合架构图

一、基于社媒挖掘的标签体系

本研究首先构建了一套完整的数据工程流程，利用 TF-IDF 文本挖掘技术与多模态模型（CLIP、Qwen-VL）对小红书平台上的特斯拉相关 UGC 内容进行系统化采集与分析，从 8117 条帖文及 22400 张图片中提炼出：“黑武士风格”、“纯净美学”、

“金属质感”、“改色潮流”、“都市霓虹”、“户外露营”、“日落公路”、“动态模糊”八大维度标签体系。

这一标签体系不仅实现了从消费者自然语言到 AI 可理解语义的桥接，更通过结构化的标签定义为后续的可控生成提供了清晰的语义锚点。

二、基于改进 FLUX 的可控生成

在算法层面，本研究对当前开源社区性能最优的 FLUX. 1 Dev 扩散模型进行了深度改进。首先，引入 In-Context LoRA（简称 IC-LoRA）排版策略，通过将多张相关图像拼接为 2×2 网格（Grid）的方式，激活 Diffusion Transformer 架构（DiT）的全局上下文学习能力，使模型在单次推理中即可生成排版连贯的成套图像。其次，创新性地提出了潜空间统计量对齐模块（Latent Statistical Alignment, 简称 LaSA），通过构建 Leader-Follower 机制，实现了在极小额外计算开销的条件下，在扩散模型的潜空间中约束 2×2 网格图像中各子图区域的宏观风格一致性。最后，针对扩散时间步的物理特性，提出了自适应衰减权重优化策略，实现了平滑训练过程。

第四节 论文组织结构

本文共分为七章。

第一章为绪论，阐述研究背景、意义、现状与技术路线。

第二章系统梳理扩散模型架构演进、个性化微调技术及风格迁移的相关理论基础。

第三章详细介绍汽车广告自动化视觉标签体系的构建过程，包括数据采集清洗、TF-IDF 挖掘及多模态数据集构建。

第四章深入阐述基于改进 FLUX 的可控生成方法，包括 In-Context LoRA 机制、潜空间统计量对齐模块（LaSA）及基于时间步的动态加权优化策略。

第五章展示实验设置与结果分析，通过定性定量评估及消融实验验证算法有效性。

第六章探讨改进型 AI 生成框架在计算广告中的商业应用价值。

第七章总结全文并展望未来研究方向。

第二章 相关工作与理论基础

第一节 广告视觉生成的理论基础

一、品牌视觉识别与整合营销传播

在现代营销体系中，品牌视觉识别系统（Visual Identity System, VIS）是构建品牌资产与传递品牌核心价值的物理基石[22]。整合营销传播（IMC）理论强调，品牌在所有触点上的传播必须发出“同一个声音”和呈现“同一种视觉”。对于汽车这一高度依赖视觉展现的垂直领域而言，其广告物料往往不是单一的图像，而是需要覆盖多视角、多场景的“成套”视觉资产。符号学理论指出，只有稳定的视觉符号系统才能确保品牌意义的准确传递[23]。如果在成套的视觉资产中，各图像的色彩、光影或整体调性出现割裂，必然会导致品牌形象的模糊与失真，削弱消费者对品牌的专业性与信任感[24]。

汽车作为典型的高客单价、高卷入度商品，消费者的购买决策不仅基于对参数与性能的理性考量，更深层地依赖于产品所代表的生活方式与情感共鸣[25]。现代汽车营销的重心已从传统的“配置清单罗列”转向“生活场景构建”[26]。场景营销理论认为，通过将产品置于特定的生活情境中（如通勤、周末郊外露营等），能够有效唤醒消费者的潜在需求，并将其转化为具体的购买理由。视觉修辞通过特定的图像符号来隐喻情感与价值，例如用“日落逆光”修辞自由与温暖，用“霓虹夜景”修辞科技与都市感。通过场景化的视觉修辞，AI 生成的广告图像能够成功将冰冷的机械参数转化为可感知的驾驶乐趣与生活愿景[25]，从而在消费者决策链路中建立起深刻的情感联结[26]。

二、标签体系与动态创意优化

计算广告的核心在于通过数据驱动实现广告信息与目标受众的高效匹配。在这一框架下，动态创意优化（Dynamic Creative Optimization, DCO）技术应运而生，其旨在根据不同的受众特征与实时场景，动态生成千人千面的个性化广告创意。然而，汽车营销的诉求往往充斥着诸如“极简科技”、“都市游牧”等高度抽象的行业术语，基础

的生成式大模型存在严重的语义鸿沟，无法直接将这些抽象概念转化为精准的视觉画面。

为了实现真正的“生成式 DCO”，必须建立一座连接“抽象营销诉求”与“AI 可计算语义”的桥梁。这就要求将传统的营销话术解构并转化为结构化的“视觉标签体系”。通过严谨的数据工程，将多维度的视觉元素（如主体、色彩、光影、背景）进行标签化提取与定义，不仅为 AI 模型提供了清晰的语义锚点，更是程序化创意生成的底层逻辑支撑。

第二节 扩散模型与 FLUX 架构演进

一、从 U-Net 到 DiT 架构

早期的扩散模型（如 Stable Diffusion 系列）普遍采用基于卷积神经网络（CNN）的 U-Net 架构作为去噪网络的骨干。尽管 U-Net 实现了高效的图像特征提取与重建，但受限于卷积操作局部感受野的固有属性，该架构难以建立对图像空间绝对位置的精准感知，从而限制了模型在复杂场景下对全局上下文信息的理解能力与对图像绝对位置的控制能力。随着 Transformer 架构在自然语言处理领域的巨大成功，研究者逐渐将其引入视觉生成任务，有效突破了传统 CNN 的空间局限性，显著提升了模型对图像生成的上下文理解能力。

Diffusion Transformer（DiT）架构的核心思想是将输入图像划分为固定大小的图像块（Patch），并将每个 Patch 转化为 Token 进行处理[5]。这种 Token 化（Tokenization）策略使得模型可以利用 Transformer 的自注意力机制（Self-Attention）在所有 Token 之间建立全局依赖关系，从而天然地提升了对图像全局上下文的理解能力。相比 U-Net 的层级式局部特征聚合，DiT 能够在单层内实现任意两个空间位置之间的直接信息交互，这为后续的多图排版学习和 2×2 网格图像中跨区域宏观风格一致性控制奠定了架构基础（传统的 Diffusion 去噪过程如图 2. 1 所示）。

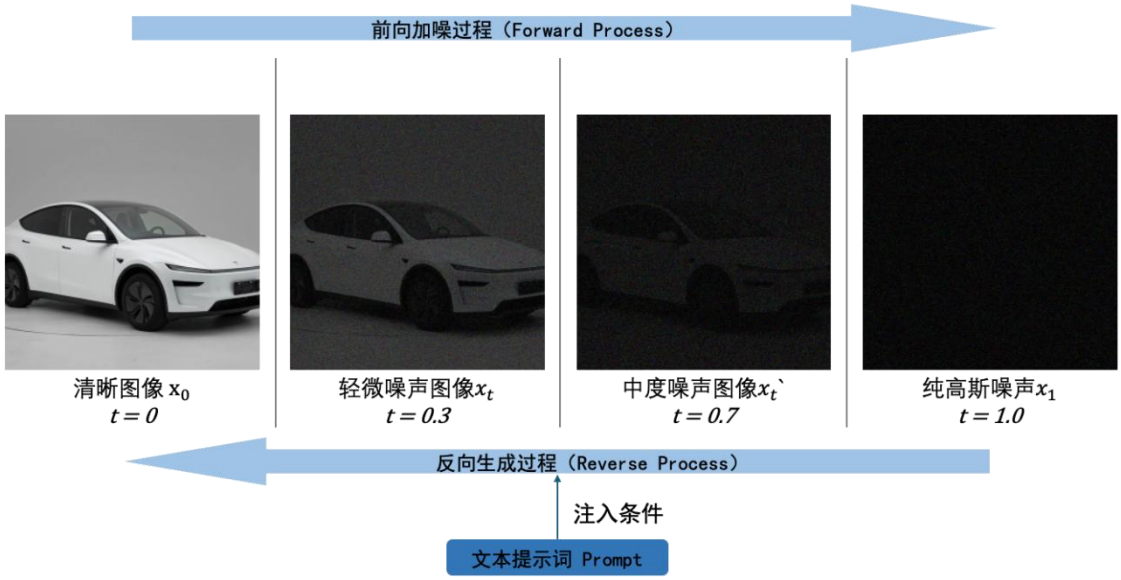

图 2. 1 Diffusion 过程示意图

二、FLUX 模型与流匹配（Flow Matching）

FLUX 模型是新一代基于 DiT 架构的文本到图像生成模型[6]，其底层采用了流匹配（Flow Matching）机制[7]，这与传统的去噪扩散概率模型（DDPM）存在区别。DDPM 基于离散的马尔可夫链进行逐步去噪，而流匹配则将生成过程建模为连续时间常微分方程（ODE）下的向量场预测问题。

在流匹配框架中，时间步$t \in [0, 1]$具有明确的物理意义：当$t \to 1$ 时，数据处于纯噪声状态；当$t \to 0$ 时，数据逐渐接近清晰的真实图像分布。模型的核心任务是学习一个速度场$v_\theta(x_t, t)$，该速度场描述了如何将噪声样本沿着最优路径推向真实数据。这种连续时间的建模方式不仅简化了采样过程，还为本文第四章提出的基于扩散时间步的动态加权优化提供了理论依据：在早期时间步（$t \to 1$）时，模型对清晰图像的预测极不准确，此时不应强加严格的 LaSA 约束；而在后期时间步（$t \to 0$）时，图像细节逐渐清晰，此时可以强力约束 Grid 内部的宏观风格一致性，FLUX 模型的整体架构如图 2. 2 所示。

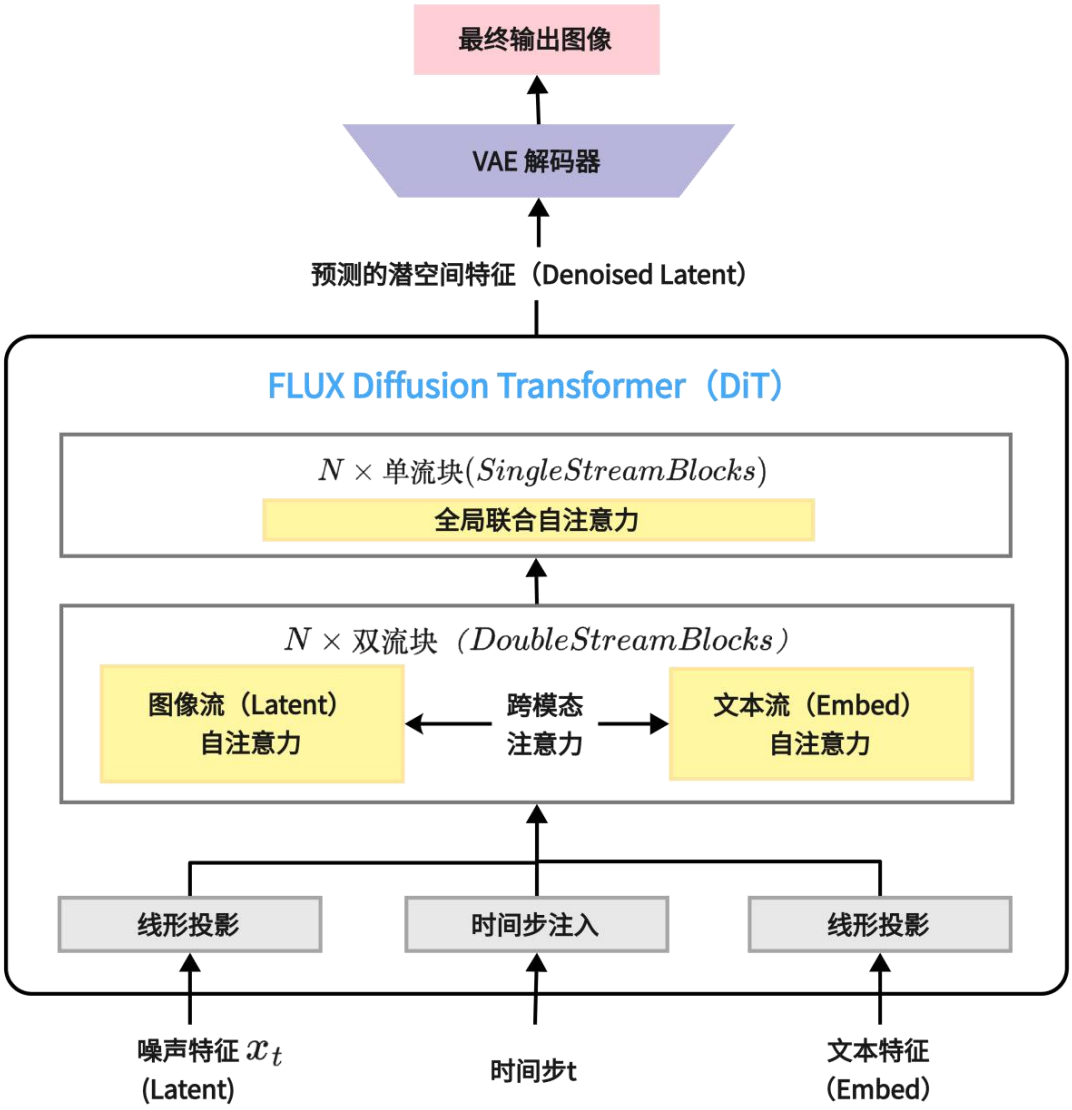

图 2. 2 FLUX 模型架构图

第三节 个性化微调技术

一、主流微调技术

随着大规模预训练扩散模型的普及，如何在不重新训练整个模型的前提下实现个性化定制成为研究热点。当前主流的微调技术主要包括 LoRA（Low-Rank Adaptation，低秩自适应）和 ControlNet 两类。

LoRA 通过在预训练模型的注意力层中引入低秩矩阵，仅训练这些新增的轻量级参数即可快速学习特定的画风、人物或物体 ID[8]。其优势在于参数量极小（通常仅占原

模型的 0.1%—1%）、训练成本低且可插拔性强，非常适合需要频繁切换风格的商业应用场景（LoRA 的微调原理如图 2.3 所示）。

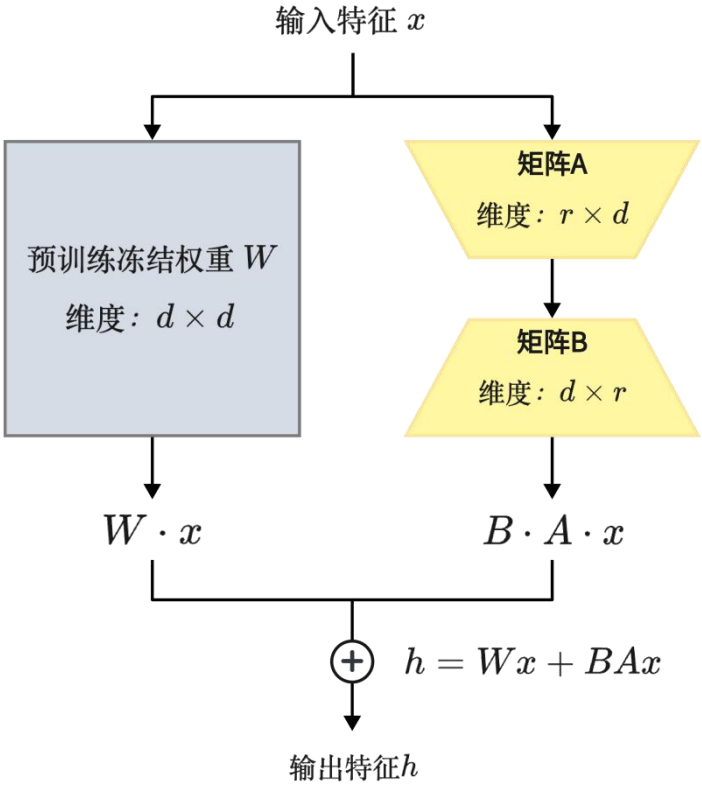

图 2.3 LoRA（低秩自适应）微调原理图

ControlNet 则采用了另一种思路。锁定原模型的所有权重，通过引入额外的编码器分支来注入显式的空间条件（如 Canny 边缘图、深度图、姿态关键点等）。这种方法在需要严格控制生成图像的几何结构时表现出色，但其缺点是需要为每种控制信号单独训练一个 ControlNet 模块，且推理时的计算开销较大。

对于本文研究的汽车广告多场景生成任务而言，由于需要在保持车辆 ID 一致的前提下生成多种风格的广告物料，低成本且灵活可插拔的 LoRA 是更优的技术选择。

二、In-Context LoRA（IC-LoRA）机制

In-Context Learning（上下文学习）最初在大语言模型领域展现出强大的 Few-Shot 学习能力，近年来研究者开始探索将这一思想引入视觉生成任务。In-Context LoRA（IC-LoRA）的核心创新在于其无需修改底层的注意力机制代码，仅通过简单巧妙的

“图像拼接（Image Concatenation）”、“联合描述（Joint Caption）”策略，即可激活 DiT 模型的视觉上下文学习能力[9]。

具体而言，In-Context LoRA 将多张相关图像在像素空间拼接为一个统一的网格（Grid），如 2×2 的四宫格布局，同时使用高度结构化的联合描述提示词。当这个拼接后的 Grid 和对应的联合描述作为单个训练样本输入模型时，DiT 的自注意力机制能够动态计算序列中每个位置与其他所有位置的关联权重，实现全局上下文的感知。这种隐式的跨区域关联使得模型能够自动学习到“多个子图区域应当展示同一主体（排版逻辑）”和“多个子图区域应当保持统一的光影、色调和质感（宏观风格一致性）”。相比传统的单图训练方式，In-Context LoRA 通过单个 Batch 内的多视角关联学习，显著提升了模型对“成套视觉资产”的生成能力，这正是汽车广告等商业场景的核心需求。

第四节 图像风格迁移与一致性控制

一、自适应实例归一化（AdaIN）

自适应实例归一化（Adaptive Instance Normalization， AdaIN）是一种经典的风格迁移技术，其核心思想是通过对齐特征图的统计量来实现风格的转移[10]。给定内容图像的特征 f_c 和风格图像的特征 f_s，AdaIN 的数学定义为：

$$\mathrm{AdaIN}\left(f_c, f_s\right) = \sigma\left(f_s\right)\left(\frac{f_c - \mu\left(f_c\right)}{\sigma\left(f_c\right)}\right) + \mu\left(f_s\right) \tag{2.1}$$

其中，$\mu(\cdot)$ 表示特征图在空间维度上的通道均值（Channel-wise Mean），$\sigma(\cdot)$表示通道标准差（Channel-wise Standard Deviation）。

AdaIN 的本质是将内容特征先标准化为零均值单位方差的分布，再通过风格特征的统计量进行仿射变换，从而实现风格的迁移任务。该方法通常作用于预训练的判别式网络（如 VGG-19）的深层特征空间，其统计量主要反映高度抽象的艺术笔触与纹理风格，在实时风格迁移任务中取得了良好效果。

二、扩散模型的一致性约束困境

尽管扩散模型在单图生成质量上取得了巨大成功，但在多图生成任务中如何保持宏观风格一致性仍是一个开放性挑战。传统的扩散损失函数（如 MSE 均方误差损失）仅关注每个像素点的精确还原，这种微观的逐像素优化目标忽略了多图之间宏观风格的统一性需求[11]。在实际应用中，这种局限性会导致明显的视觉割裂：例如在本文的初步实验中，基础的 Flow Matching 损失训练出的模型生成的 2×2 Grid 常常出现不同子图区域的主体、色调、宏观风格不一致问题。这是因为基础损失仅约束了速度场预测的准确性，而没有对不同子图之间的特征分布施加任何显式约束。In-Context LoRA 方法通过数据工程激活了 DiT 模型的上下文能力,但对生成图片的主体、宏观风格一致性控制仍然是隐式约束，在实践中依然存在生成内容一致性不足、身份保持不稳定等问题。

三、VAE 潜空间的统计量基础

为增强 DiT 模型生成内容一致性约束能力，本研究探索在潜空间（Latent Space）引入额外的统计量约束项。与 AdaIN 基于 VGG 网络特征图的统计量对齐不同，这一机制直接作用于 FLUX 模型的 VAE 潜空间。VAE（变分自编码器）作为深度生成模型的一种形式，是由 Kingma 等[21]于 2014 年提出的基于变分贝叶斯（Variational Bayes, VB）推断的生成式网络结构。

近期研究表明，在扩散模型的 VAE 潜空间中，特征的通道均值与方差在统计意义上保留了原始图像的全局色彩分布与变异性特征。Arias 等发现 Stable Diffusion 的 VAE 潜空间中色彩信息沿对手色轴（opponent axes）编码在某些特定通道，而强度（intensity）与形状也主要在某些特定通道编码，通道统计量直接对应原始图像的全局色彩分布[13]。在保持各通道方差不变的前提下，仅调整初始噪声的通道均值即可精确控制生成图像的全局色彩组成，证明了潜空间通道统计量对宏观色彩变异性的因果主导作用[14]。Leng 等通过通道均值和方差统计分析证明 VAE 潜空间通道统计量直接影响生成性能与全局结构；端到端调优时需显式对齐 latent statistics[15]。在扩散模型 VAE 潜空间中调整通道统计量实现颜色、风格迁移，证明潜空间统计量对齐可实现宏观风格一致性[16]。这些发现揭示了 VAE 潜空间与 VGG 特征空间的本质差异：前者的统计量直接编码了像素空间的全局色彩与光影分布，后者则反映高层抽象的纹理与笔触风格。因此，在潜空间直接操纵统计量具有物理可解释性与因果控制力，为本文第四章提出的 LaSA 模块提供了坚实的理论支撑。

第五节 本章小结

本章主要对本文研究所涉及的相关工作与核心理论基础进行了系统性的梳理与探讨，为后续算法框架的设计奠定了理论前提。

首先，本章回顾了扩散模型从传统 U-Net 向 DiT 架构的演进历程，指出了 Token 化策略在建立图像全局依赖与上下文理解方面的架构优势。在此基础上，本文说明了新一代 FLUX 模型底层的流匹配（Flow Matching）机制，明确了连续时间常微分方程中时间步t的物理意义，这为本文后续设计基于扩散时间步的动态加权优化策略提供了直接的理论支撑。

其次，本章对比了 LoRA 与 ControlNet 等主流微调技术，结合汽车广告多场景生成的商业需求，论证了采用轻量级 LoRA 技术的合理性。同时，详细探讨了 In-Context LoRA（IC-LoRA）机制，揭示了其如何通过“图像拼接”与“联合描述”的数据工程，有效激活 DiT 模型的视觉上下文学习能力，以满足多图排版与成套视觉资产的生成需求。

最后，针对多图生成任务中宏观风格易割裂的痛点，本章探讨了自适应实例归一化（AdaIN）的统计量对齐原理，并指出了传统扩散模型的基础 Flow Matching 损失的固有局限性。基于上述理论分析，本章明确了仅靠 In-Context LoRA 数据工程的隐式约束仍显不足，从而自然引出了本文的核心研究动机：即需要在潜空间中引入基于 Leader-Follower 机制的动态统计量对齐损失（Dynamic LaSA Loss）。这一理论推演为第四章核心算法框架的提出做好了充分的铺垫。

第三章 汽车广告自动化视觉标签体系与数据工程

本章将系统阐述面向汽车广告自动化生成的数据工程全流程，首先介绍基于小红书平台的社媒数据采集与多层次清洗策略；其次，详细推演利用 TF-IDF 算法挖掘视觉语义特征的过程；再次，构建具有广告学意义的八维视觉标签体系；最后，阐述面向 In-Context LoRA 训练的多模态广告数据集构建工程，包括智能裁切、相似度拼接与联合描述生成等关键技术环节。

第一节 汽车社媒数据采集与清洗

一、数据源选择与检索策略

鉴于 Tesla Model Y 连续三年（2022 年至 2025 年）位居中国 SUV 销量榜首，其在新能源汽车市场拥有极高的保有量及庞大的用户基础与社区文化[4]。因此，选取该车型作为核心实体，能够天然保证视觉数据的丰富性与覆盖度。

在媒介平台的选择上，本研究选定小红书作为核心数据源。首先，汽车消费属性的变迁与平台生态的高度契合。根据《2025 年车生活场景白皮书》，小红书平台目前已沉淀超 2 亿汽车兴趣用户，日均相关搜索量超千万次[27]。特斯拉 Model Y 作为主打都市通勤与科技体验的纯电 SUV，其目标受众高度关注车辆在多元生活场景（如户外露营、近郊短逃离、都市探索）中的延展性，这与小红书海量的 UGC（用户生成内容）“赛博田野”生态形成了完美的供需匹配。其次，消费者汽车购买决策链路的“场景化”前置。《新能源车行业营销趋势洞察及展望：2024-2028 深度报告》指出，高达 28.1%的消费者在购车研究阶段首选小红书，这一比例已超越传统的垂直汽车网站；且有 47.8%的用户会因真实车主的内容分享而直接影响购买决策[28]。相较于传统汽车论坛

[27] 小红书. 2025 年车生活场景白皮书[R]. 上海:小红书科技有限公司, 2025：第 15 页。

[28] 北京嘉利智联营销管理股份有限公司. 新能源车行业营销趋势洞察及展望：2024-2028 深度报告[R/OL]. 北京:中国国际公共关系协会, 2026.[2026-04-02]https://www.cipra.org.cn/site/content/4632.html

侧重于枯燥的机械参数比对，小红书更侧重于“场景化种草”。这种“以场景唤醒需求”的内容生态，不仅完美契合了现代汽车营销中“视觉修辞”与“情感连接”的诉求，更天然地满足了本研究所需的“多场景、成套视觉资产”的数据要求。因此，以小红书平台作为特斯拉 Model Y 视觉标签体系的数据挖掘源，不仅具有极高的数据信噪比，更具备极强的广告商业代表性与普遍指导意义。

为了构建高质量的汽车广告视觉数据集，本研究首先基于市场调研与探索性检索制定了关键词策略。在正式采集前，本研究在小红书平台进行了探索性检索。通过手动检索“特斯拉 Model Y”等泛化标签，观察发现“黑武士”、“露营”、“极简科技”等词汇在头部高赞笔记中频繁出现，且往往伴随着高质量的视觉呈现。为了确保数据采集能够精准服务于后续的广告商业目标，避免底层数据工程与顶层营销逻辑脱节，本研究构建了一套“检索-标签-价值”相统一的三层映射框架（详见第三节表 3.2）。在数据检索阶段，本研究严格遵循该框架，制定了递进式的三层关键词检索策略（见表 3.1）。

表 3.1 三层关键词检索策略

检索层级	关键词组合	目标内容
实体功能层检索	“特斯拉 Model Y”等	展示车辆基础物理属性的高清图像
风格情感层检索	“黑武士”、“特斯拉改色”等	个性化视觉风格图像
语境场景层检索	“特斯拉露营”、“特斯拉通勤”等	车辆融入生活方式的叙事性图像

通过上述矩阵化检索策略，本研究最终采集到 8117 条帖文及约 2.2 万张原始图片，为后续的视觉标签体系构建奠定了坚实的数据基础。

二、文本正则化清洗

原始社媒文本数据普遍存在大量 Emoji 表情、引流性 URL 链接及营销性词汇（如“戳链接”、“私信我”等），这些冗余信息会严重干扰后续的语义特征挖掘。本研究利用 Python 的 re 正则表达式库，将“标题”、“正文”、“tag 标签”三段单独的文本清洗后合并为一段完整帖文。

经过上述规范化处理，原始文本的噪声信息被有效剔除，为后续 TF-IDF 算法的准确计算提供了高质量的文本语料。

三、基于 CLIP 的图像筛选机制

在 2.2 万张原始图像中，存在大量纯文字海报、人像自拍、风景照等与汽车主体无关的干扰图像。为了高效完成图像初筛，本研究引入了 OpenAI 开源的 CLIP（Contrastive Language-Image Pre-training）模型作为零样本分类器[17]。

具体而言，本研究采用 CLIP ViT-B-32 预训练权重，设计了“正样本类别竞争过滤（Category Competition）”和“负样本置信度阈值过滤（Confidence Threshold）”双层过滤机制。正样本类别竞争过滤仅保留“车辆”类别得分最高的图像；负样本置信度阈值过滤进一步筛除诸如“人像”、“文字”、“纯风景照”等任务无关图片以及“人车合影”、“车辆主体受到遮挡”等影响训练效果的图片，以确保图像中车辆主体清晰明确。

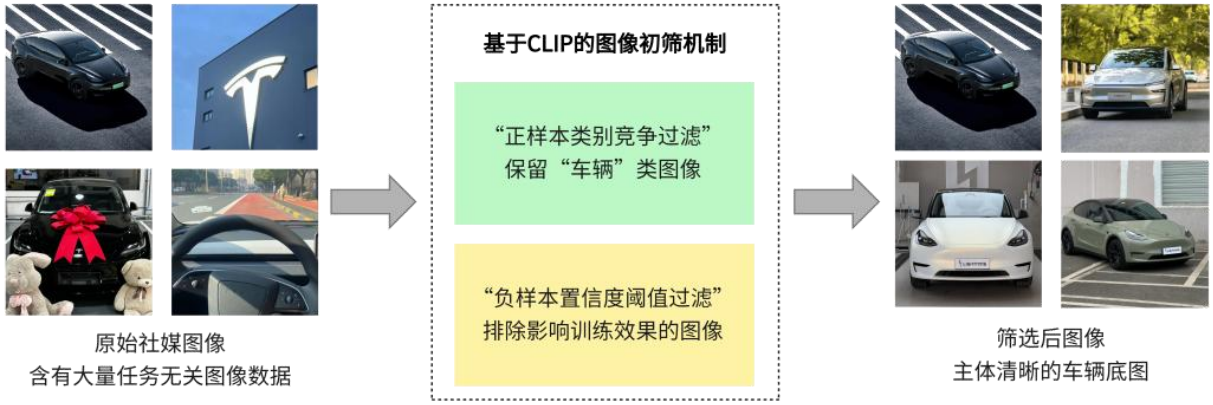

图 3.1 基于 CLIP 的图像初筛示意图

经过上述两级 CLIP 初筛机制，本研究最终从 2.2 万张原始图像中提取出 6559 张主体清晰的车辆底图，大幅降低了后续人工审核的工作量。

第二节 基于 TF-IDF 的语义特征挖掘

通用的中文分词工具（如 jieba）往往难以准确切分汽车垂直领域的专业词汇。为此，本研究针对特斯拉品牌定制了领域词典，涵盖“单踏板模式”、“哨兵模式”、“黑武士”、“改色膜”、“城市夜景”、“自驾游”等词汇。同时，本研究构建了

“负面清洗词表”，剔除与视觉生成无关的词汇（如“价格”、“提车”、“保险”、“贷款”等），以确保 TF-IDF 权重计算聚焦于视觉语义特征。

TF-IDF（Term Frequency-Inverse Document Frequency）是信息检索领域的经典算法，其核心思想是通过词频（TF）与逆文档频率（IDF）的乘积来衡量词汇在语料库中的重要性[18]。在本研究中，每条社媒帖文被视为一个文档，TF-IDF 公式为：

$$\text{TF-IDF}(w,d) = \text{TF}(w,d) \times \log\left(\frac{N}{\text{DF}(w)}\right) \tag{3.1}$$

其中，$\text{TF}(w, d)$表示词汇w在文档d中的出现频率，N为语料库中文档总数，$\text{DF}(w)$为包含词汇w的文档数量。

通过对 8117 条清洗后的帖文进行 TF-IDF 计算，本研究提取了 Top-50 高频语义词汇，并生成了词云图（图 3.2）。从 TF-IDF 结果可以看出，“露营”、“续航”、“氛围”、“自驾”、“改色”、“城市”等词汇权重显著，这些高频词直接反映了特斯拉用户群体的审美偏好与使用场景，为后续标签体系的维度划分提供了数据驱动的决策依据。

图 3.2 汽车垂直领域高频语义 TF-IDF 词云图

第三节 多维视觉标签体系构建

一、八维视觉标签体系构建

结合 TF-IDF 挖掘结果，本研究在排除如“续航”、“心动”、“体验”等难以视觉化的标签后，定义了八大视觉标签维度（见表 3.2），每个维度对应 30 至 140 张人工精选图像，共计 452 张高质量标签图像。本研究将前文数据采集阶段的“三层检索策略”、TF-IDF 挖掘出的“八维视觉标签”进行了深度整合，构建了“检索-标签-营销”统一的三层映射框架。该框架打通了从“原始社媒数据”到“AI 自动化标签”，再到“广告营销价值”的完整闭环，实现了从“抽象营销话术”到“可视化视觉元素”的精准映射，解决了基础大模型在理解营销术语时的语义鸿沟问题。

表 3.2 八维视觉标签体系

层级	对应检索词	八维视觉标签	商业逻辑与营销价值
实体功能层	“特斯拉 Model Y”等	“纯净美学”“金属质感”	聚焦产品本体，传达核心卖点。通过极简的视觉语言与材质光泽，隐式且高级地传达车辆的工业设计美学、科技属性与制造工艺
情感风格层	“黑武士”“特斯拉改色”等	“黑武士风格”“改色潮流”	精准视觉修辞，触发情感共鸣。通过对色彩与光影的控制，精准匹配不同圈层消费者的个性化情感诉求。
语境场景层	“特斯拉露营”“特斯拉通勤”等	“都市霓虹”“户外露营”“日落公路”“动态模糊”	构建生活方式，唤醒消费需求。覆盖从自然户外到城市夜景的全场景谱系，将汽车融入为具象的生活愿景，在特定语境中触发购买动机。

二、自动化标签体系的普遍性价值与行业泛化意义

本研究以特斯拉 Model Y 为核心实体提炼出的八大视觉标签，其核心学术贡献与商业价值在于提出并构建了一套面向生成式 DCO（动态创意优化）的“自动化视觉标签提取范式”。

在传统的计算广告中，标签体系往往高度依赖人工经验预设，不仅耗时耗力，且难以敏捷捕捉社交媒体上瞬息万变的营销趋势。本研究构建的“社媒数据挖掘-NLP 高频语义提取-视觉特征映射-AI 可控生成”这一标准化工程链路，具有极强的跨品类泛化能力与行业普遍意义。该范式可直接复用于其他车型、品牌，从而快速建立其对应专属的 AIGC 视觉字典。该“检索-标签-营销”三层映射框架同样适用于美妆、3C 数码、奢侈品等高度依赖视觉修辞的商业领域。

第四节 面向 In-Context LoRA 的多模态广告数据集构建

前文构建的八大视觉标签体系虽然在营销语义层面为 AI 生成提供了精准的锚点，但直接从社交媒体上抓取的原始图像在构图规范性、视觉连贯性以及文本描述的结构化程度上，仍远未达到微调底层扩散模型的要求。特别是本研究在第四章即将引入的 In-Context LoRA（IC-LoRA）机制，其核心在于通过图像的物理拼接来激活模型的全局上下文学习能力，这就要求训练数据必须具备极高的空间排版规整度与网格内部的风格一致性。

因此，本节的核心任务是完成从“营销概念标签”到“机器可学习的高质量多模态数据集”的工程跨越。具体而言，本节针对社媒图像构图杂乱、单图缺乏上下文关联、以及传统单图描述无法指导多图排版等三大痛点，依次引入目标检测（YOLOv8）、特征相似度匹配（CLIP）与多模态大模型联合打标（Qwen-VL）技术，旨在构建一套高度结构化、风格强连贯的专属广告训练数据集，为后续算法的稳定收敛与可控生成奠定坚实的数据基石。

一、基于 YOLO 的智能居中裁切

在实际的社媒图像中，车辆主体可能出现占比过小的情况（如远景拍摄、构图不佳等），这会导致训练后的模型生成的图像中车辆视觉主体不够突出。为此，本研究引入了 YOLOv8 目标检测模型进行智能裁切[19]（如图 3.3 所示）。

其算法逻辑与流程如下：

1. 使用 YOLOv8 检测图像中的“car”类别边界框（Bounding Box）。计算边界框中心点坐标(x_c, y_c)；
2. 以中心点为基准，裁切出固定尺寸（512×512 像素）的方形区域，确保车辆主体位于画面正中且占比充足；
3. 若检测到多个车辆目标，则优先选择面积最大的边界框。

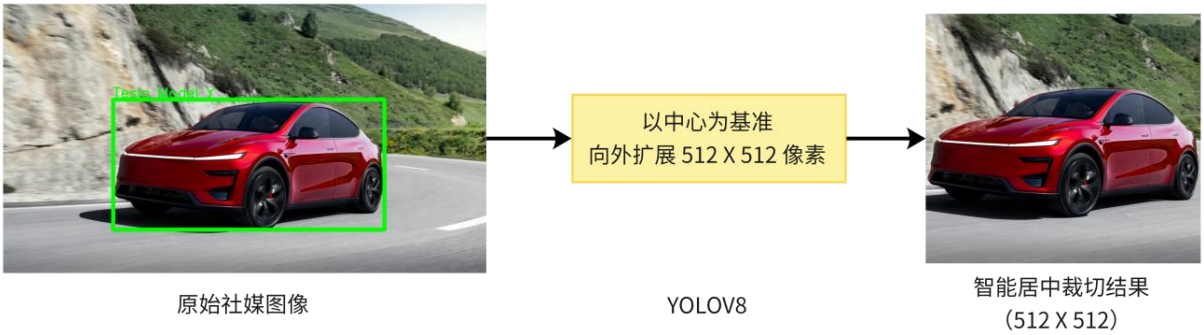

图 3.3 基于 YOLOv8 的车辆主体智能居中裁切流程

二、基于 CLIP 特征的相似度网格拼接

为了实现 In-Context LoRA 的上下文隐式学习，本研究需要将视觉风格相近的 4 张图像拼接为 2×2 网格（Grid）。即使处于同一风格标签下的图像经过简单的随机拼接仍然可能导致 Grid 内部宏观风格割裂（例如同一条帖文的图像可能被拼接到不同 Grid 内）。为保证 Grid 内部的语义一致性，本研究基于 CLIP 特征的相似度进行网格拼接，从而有效保证上下文的连贯性（如图 3.4 所示）。

其算法逻辑与流程如下：

1. 使用 CLIP 模型（ViT-B-32）提取每张图像的视觉 Embedding（512 维向量）；
2. 在每个标签文件夹内，计算所有图像两两之间的余弦相似度矩阵；
3. 采用贪心聚类策略：首先随机选择一张图像作为“种子”，然后选择与其相似度最高的 3 张图像，组成一个 4 图组合；
4. 将 4 张图像按照左上、右上、左下、右下的顺序拼接为 1024×1024 像素的网格图（Grid）；

通过上述策略，本研究最终从 8 个标签文件夹（每个约 15 张图像）中生成了 113 组高相似度的 2×2 网格图像，确保了每个 Grid 内部的视觉风格高度一致。

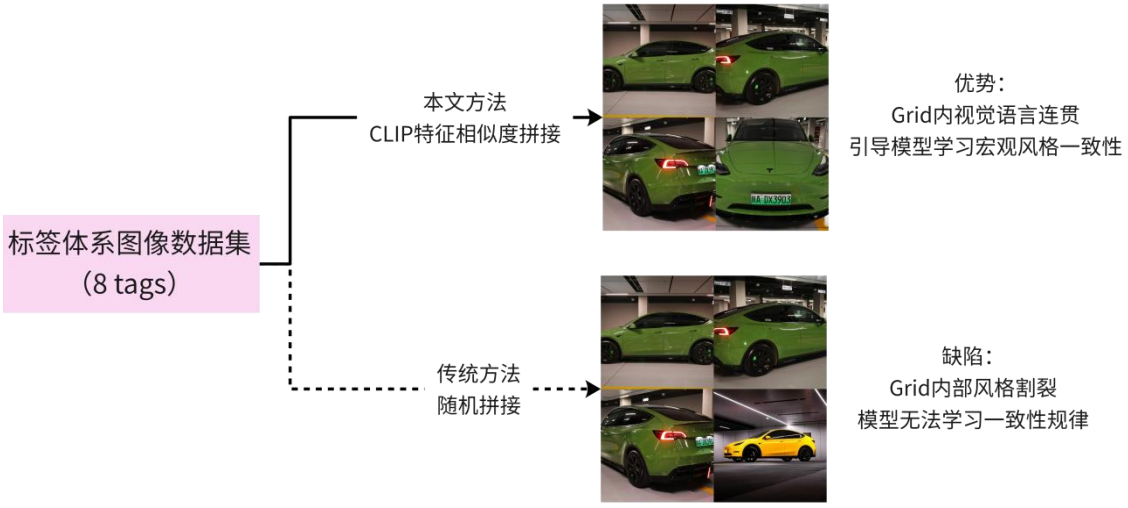

图 3.4 基于 CLIP 特征相似度的网格效果对比

三、基于 Qwen-VL 多模态大模型的联合描述

传统的单图描述（Single Captioning）无法体现 Grid 内部多张图像的整体关联性。为此，本研究利用阿里云的 Qwen-2.5-VL-72B 多模态大模型[20]，为每个 2×2 Grid 生成符合 In-Context LoRA 要求的高度结构化的联合描述（Joint Caption）。联合描述的具体结构如下：

[GLOBAL DESCRIPTION]；+ [IMAGE1]… + [IMAGE2]… + [IMAGE3]… + [IMAGE4]…

这种“整体风格+局部细节”的联合描述策略，不仅为模型提供了明确的全局语义引导（整体风格词），还保留了每个子图的独立特征（局部描述），为 In-Context LoRA 的上下文学习提供了高质量的文本条件。

最终，经过上述三个环节的精细化处理，本研究构建了包含 113 组高质量训练对（每个训练对包含 1 张 2×2 Grid 图像和 1 段结构化联合描述）的多模态广告数据集，为后续的模型微调奠定了坚实的数据工程基础。

第五节 本章小结

本章系统阐述了面向汽车广告自动化生成的数据工程全流程。首先，本章确立了以小红书平台为核心的数据源，制定了“主体－风格－场景”的三层定向检索矩阵，并

通过文本正则化清洗与基于 CLIP 模型的两级图像初筛机制，有效剔除了冗余噪声，构建了高质量的原始车图语料库。其次，针对汽车垂直领域的特殊性，本章通过构建定制化领域词典与 TF-IDF 算法，精准挖掘了高频视觉语义特征，并据此推演出了包含八大核心维度的视觉标签体系。该体系遵循“实体功能-情感风格-语境场景”的三层映射商业逻辑，成功实现了从抽象营销诉求到具象视觉元素的精准映射，有效弥补了基础大模型在理解营销术语时的语义鸿沟，并为跨行业的生成式 DCO 提供了具有普遍意义的标签提取范式。

此外，为满足 In-Context LoRA（IC-LoRA）对上下文隐式学习的严格要求，本章设计并实现了一套标准化的多模态广告数据集构建工程。具体而言，通过 YOLOv8 目标检测实现了车辆主体的智能居中裁切；利用 CLIP 视觉特征相似度完成了高连贯性的 2×2 网格（Grid）拼接；并借助 Qwen-2. 5-VL-72B 多模态大模型生成了包含“全局风格+局部细节”的高度结构化联合描述（Joint Caption）。

综上所述，本章通过精细化的数据清洗与跨模态工程，最终构建了包含 113 组高质量训练对的专属数据集。这不仅为模型提供了精准的语义锚点与排版范式，更为第四章基于改进 FLUX 架构的广告图像可控生成，以及引入动态潜空间统计量对齐损失函数（Dynamic LaSA Loss）的核心算法设计，奠定了坚实的数据与工程基础。

第四章 基于改进 FLUX 的广告图像可控生成方法

本章是全文的核心技术章节，将详细阐述基于改进 FLUX 模型的汽车广告图像可控生成算法。首先给出算法框架总览，随后深入解析 In-Context LoRA（IC-LoRA）的排版与上下文学习机制，并重点推导潜空间统计量对齐模块（LaSA），最后提出基于扩散时间步的动态加权优化策略。

第一节 技术框架总览

本文提出的改进型 FLUX 训练框架的完整 Pipeline 如图 4. 1 所示。整个流程可概括为以下关键步骤：

1. 输入 Grid 数据：将第三章构建的 1024×1024 分辨率的 2×2 Grid 图像及其对应的联合文本描述（Joint Caption）作为训练输入；
2. FLUX Flow Matching 前向加噪：按照流匹配机制，在随机采样的时间步$t \in [0，1]$上对潜空间特征进行线性插值加噪，构造噪声状态x_t；
3. 计算基础损失与 LaSA 损失：基于模型预测的速度场，首先计算传统的 Flow Matching 基础损失；同时根据反推的清晰图像x_0提取统计量，构建基于潜空间统计量对齐的 LaSA 损失（L_{LaSA}）；
4. 反向传播更新 LoRA 权重：将基础损失与动态加权的 LaSA 损失进行线性组合，通过梯度反向传播仅更新低秩适配器（LoRA）的参数，保持 FLUX 基座权重冻结。

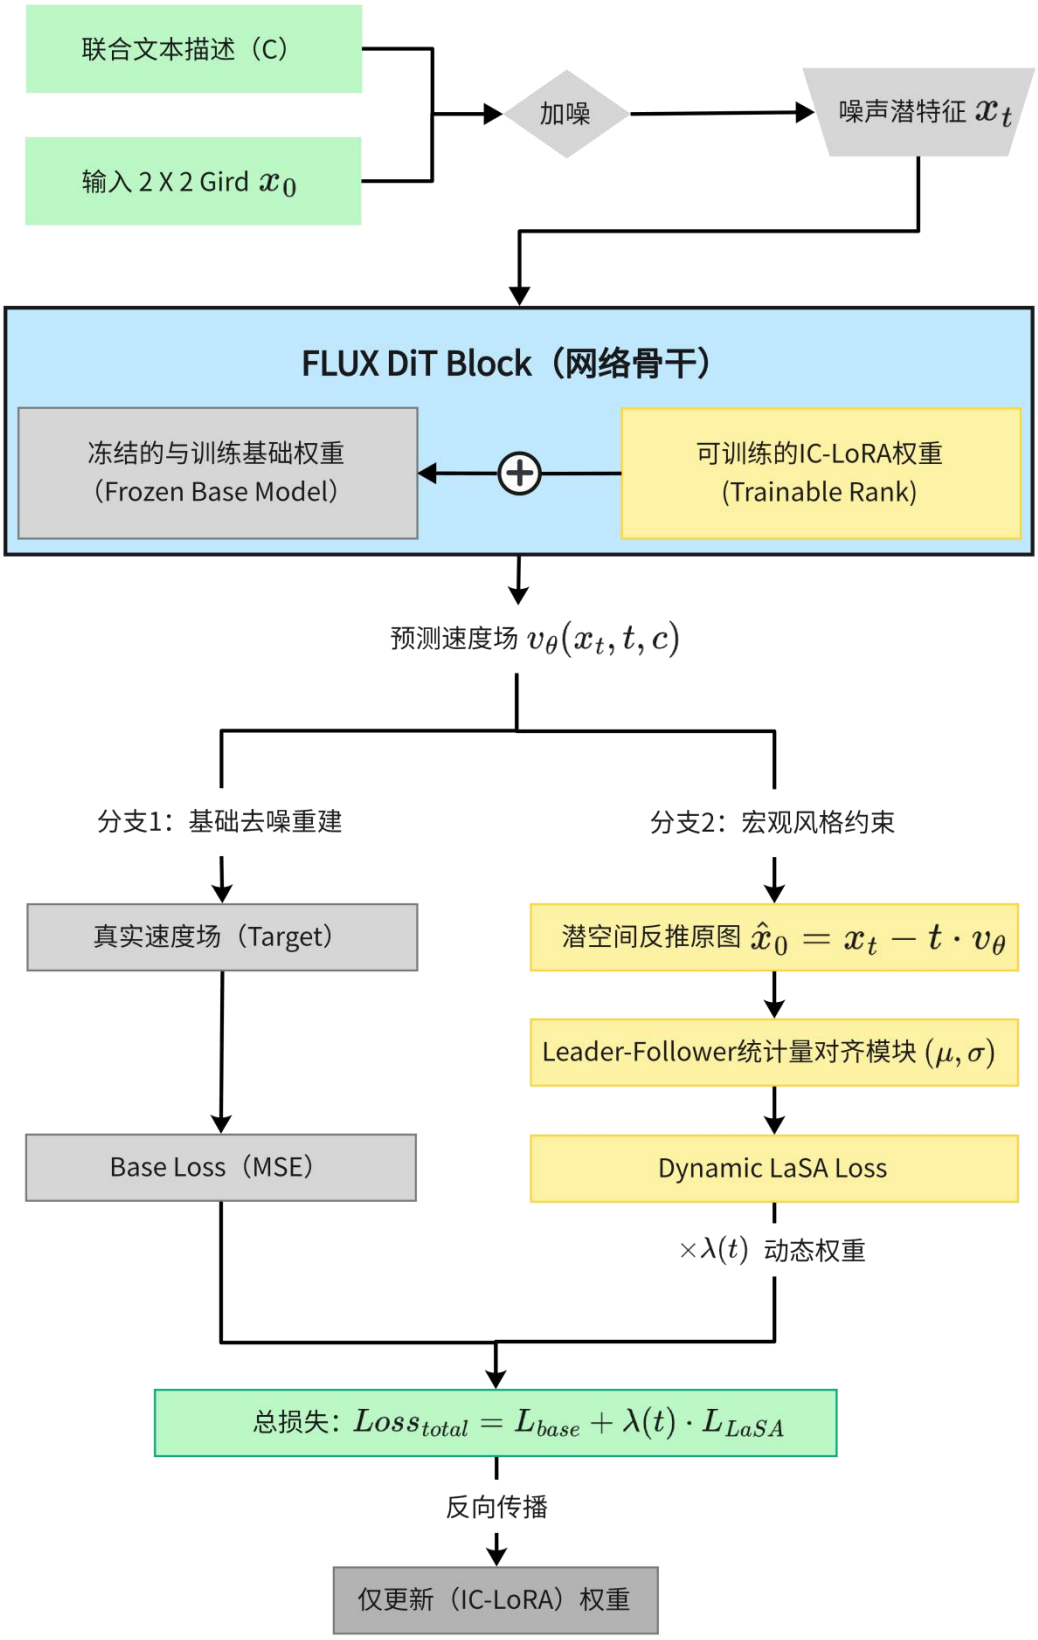

图 4. 1 改进型 FLUX 训练框架流程图

第二节 基于 In-Context LoRA 的上下文学习

In-Context LoRA（IC-LoRA）的核心在于通过训练数据的高度结构化预处理实现复杂的上下文学习。具体而言（如图 4.2 所示），本研究将 4 张相似风格的汽车图像物理拼接为单个 2 × 2 Grid。在训练过程中，这个 Grid 被作为单个样本输入 FLUX 模型。由于 FLUX 采用 DiT 架构，其全局自注意力机制会在单个 Batch 内自然地计算 Grid 中所有 Token 之间的相关性。

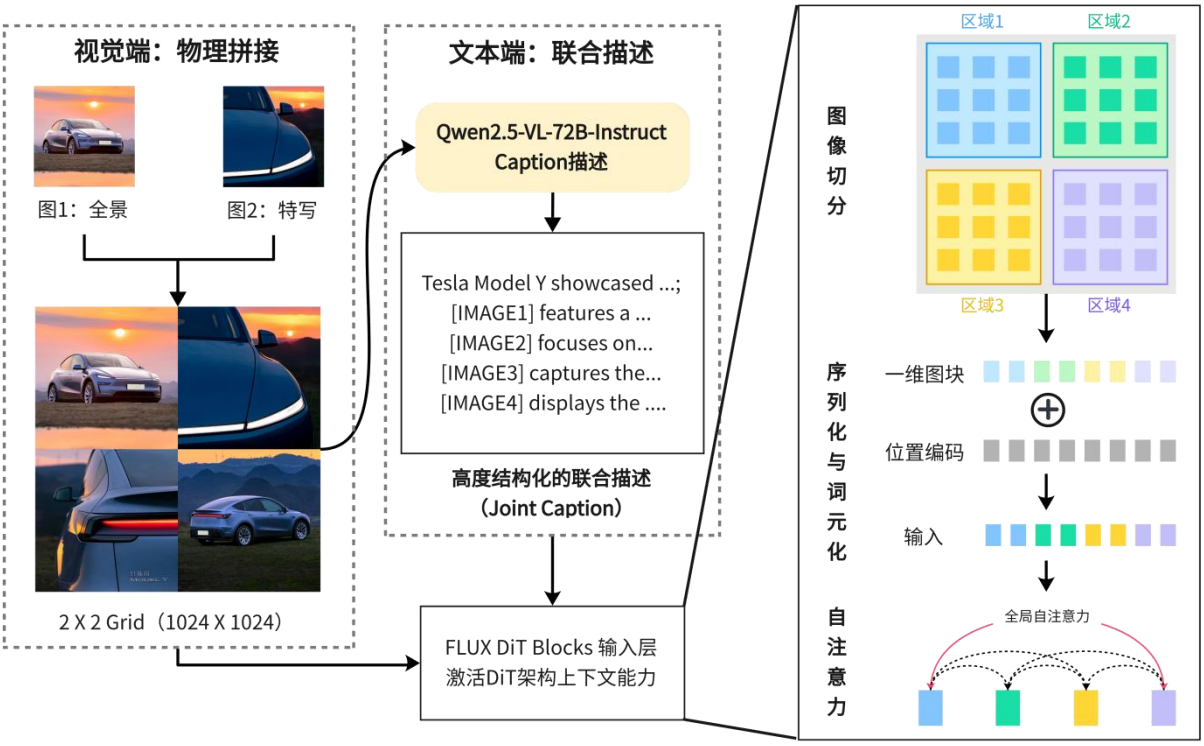

图 4.2 In-Context LoRA 训练范式与 DiT 上下文学习机制

这种拼接策略迫使模型在优化损失函数（即第三节中的基础损失）时，必须同时考虑四个子图区域在空间排版、视觉连贯性以及宏观风格统一性上的约束。模型逐渐学会四个子图区域的内容语义、内容主体等须具有内部关联性和一致性。这种隐式关联学习无需修改底层的注意力代码，仅依靠数据工程激活 DiT 模型本身的上下文能力，即可实现多视角图像的上下文学习能力。

为了进一步强化模型对全局风格的理解，本研究在文本层面引入了联合描述（Joint Caption）策略。不同于传统训练中为每张子图单独标注文本，本研究为 2×2 Grid 构建统一的描述，强制要求文本中包含“全局风格词”以及“局部细节词”。这种联合文本对齐机制引导模型将“全局风格词”的语义投射到四个子图的共同特征空间上，使得模型在生成时能够自觉地在整个 Grid 范围内施加统一的风格约束。这一设计为后续的特征层宏观风格约束提供了文本层面的先验支持。

第三节 潜空间统计量对齐模块（LaSA）

一、基础 Flow Matching 损失的局限

FLUX 模型基于流匹配机制，其基础损失函数（MSE）为：

$$L_{\text{base}} = \mathbb{E}_{\mathbb{t},\mathbb{x}_{\mathbb{0}},\epsilon}\left[|\nu_{\theta}\left(x_t, t\right) - \text{target}|^2\right] \tag{4.1}$$

其中，ν_θ表示模型预测的速度场，target 为理论上的真实速度场。

然而，这一损失函数本质上是一种微观的单像素去噪损失，关注局部像素的精确还原，其最初设计逻辑中没有关于 2×2 Grid 内部四个子图区域在宏观风格（如整体色调、对比度、光影氛围）一致性上的专门优化。在实际训练中发现，仅依赖基础损失会导致生成的 2×2 Grid 出现一定程度上的宏观风格割裂感，典型表现为“右上角子图偏暖色调（黄昏）、左下角子图偏冷色调（白天）”，或者不同子图的色温、饱和度、细节丰富度存在差异，严重影响广告物料的商业质感与品牌视觉资产一致性。

二、潜空间原图反推

为了在训练过程中直接评估并约束 2×2 Grid 内部的风格一致性，必须从当前噪声状态x_t反推出清晰的潜空间图像x_0。根据流匹配的原理，可通过以下公式实现反推（反推过程的物理意义如图 4. 3 所示）：

$$\widehat{x_0} = x_t - \mathrm{t}\cdot\nu_{\theta}\left(x_t, t\right) \tag{4.2}$$

其中，t为当前时间步，$\nu_{\theta}\left(x_t,\ t\right)$为模型预测的速度场。

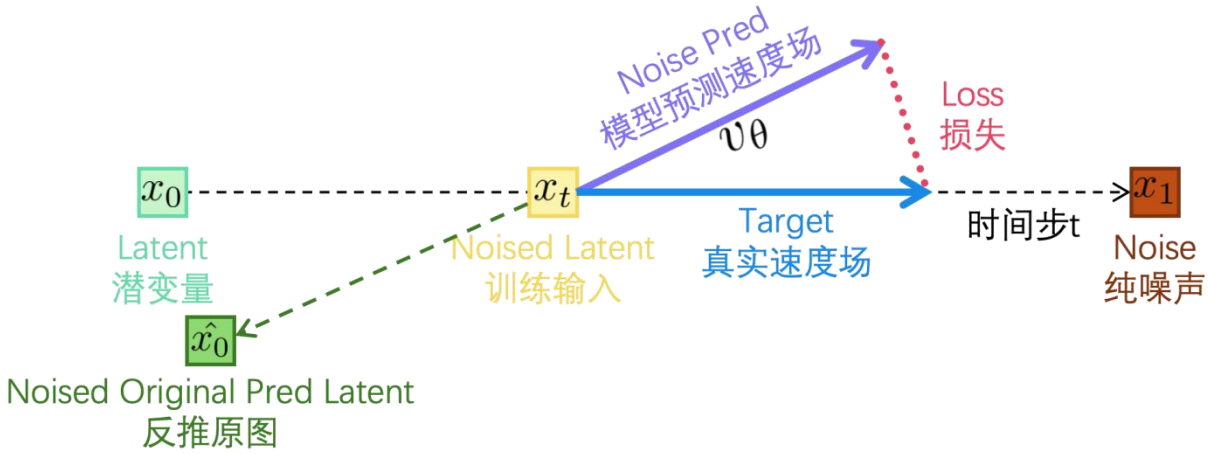

图 4.3 Flow Matching 与反推原图

该公式的物理意义在于：模型预测的速度场指示了从噪声状态回到清晰图像的“方向”，通过减去$t \cdot v_\theta$ ，即可近似还原出清晰的潜空间特征图$\widehat{x_0}$，这一反推操作为后续在特征层面计算统计量并施加统计量约束提供了基础。

三、基于 Leader-Follower 的统计量对齐机制

受自适应实例归一化（AdaIN）算法中“对齐特征图通道统计量即可实现风格迁移”这一物理直觉的启发，本研究提出了潜空间统计量对齐（Latent Statistical Alignment, LaSA）模块，并设计了“Leader-Follower”机制。

但本文方法与 AdaIN 存在本质差异。AdaIN 作用于 VGG 网络的高层特征空间，其统计量反映的是抽象的艺术纹理与笔触风格；而本文的 LaSA 机制直接前置并应用于 FLUX 模型的 VAE 潜空间（Latent Space）。现有研究已证明，VAE 潜空间的通道统计量（μ, σ）在统计意义上直接编码了原始图像的全局色彩分布与变异性特征[13][14]。具体而言，通道均值（μ）控制全局色调与亮度基准，通道标准差（σ）控制对比度与色彩变异性。因此，直接在 VAE 潜空间操纵通道统计量，具有物理可解释性与因果控制力，能够以极低计算开销实现对最终生成图像宏观色彩与光影分布的精确约束[12][16]。

具体而言，将 2×2 Grid 在空间维度上为四个子图像区域（左上、右上、左下、右下）（VAE 潜空间的数据形状如图 4. 4 所示），定义左上角子图为 Leader，其余三个子图为 Follower。

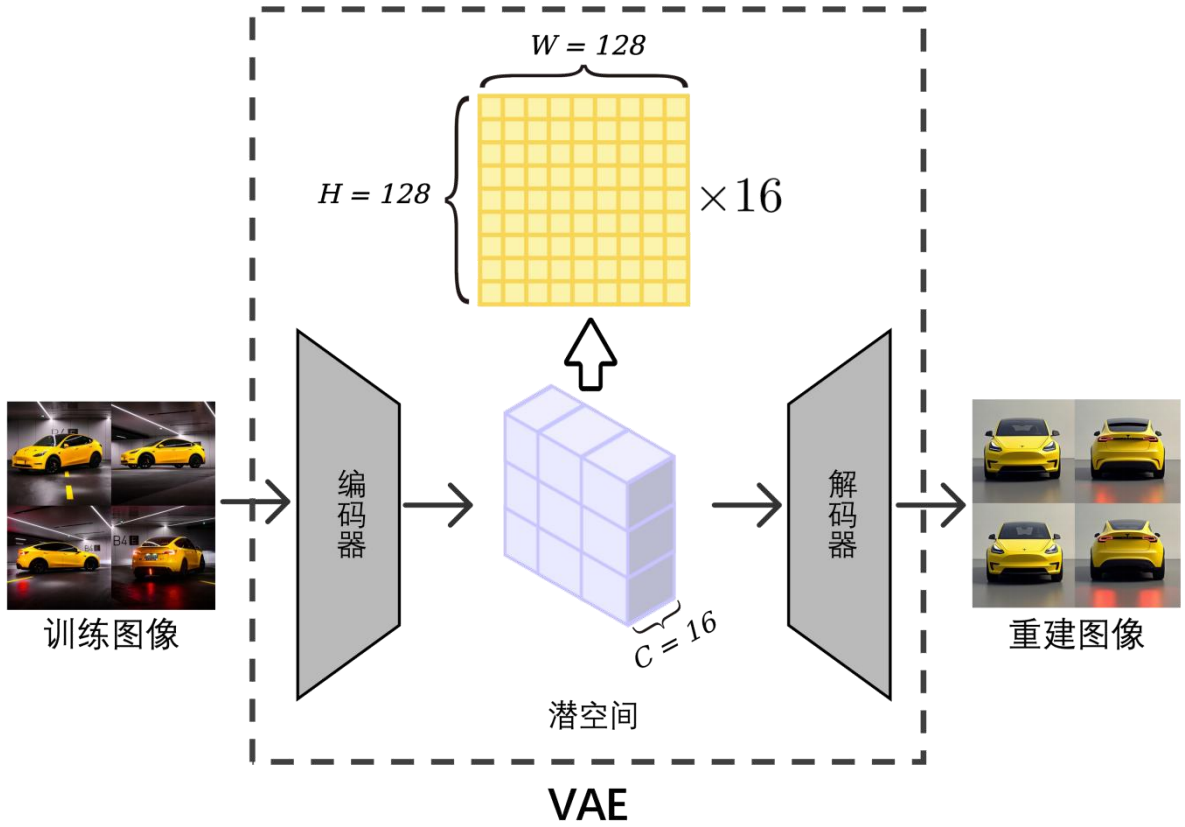

图 4.4 VAE 潜空间数据形状示意图

对于反推得到的清晰潜空间特征（latents）$\widehat{x_0} \in \mathbb{R}^{\mathbb{B}\times\mathbb{C}\times\mathbb{H}\times\mathbb{W}}$，首先在空间维度上进行切分，得到四个子特征图$\widehat{x_0^{(i)}}, i = 1,2,3,4$（Leader-Follower 机制的对齐流程如图 4.5 所示）。对于 Leader（$i = 1$），计算其在通道维度上的统计量：

$$\mu_{\text{leader}} = \frac{1}{HW}\sum_{h,w}\widehat{x_0^{(1)}}\left[:,:,h,w\right] \tag{4.3}$$

$$\sigma_{\text{leader}} = \sqrt{\frac{1}{HW}\sum_{h,w}\left(\widehat{x_0^{(1)}}\left[:,:,h,w\right] - \mu_{\text{leader}}\right)^2 + \epsilon} \tag{4.4}$$

其中，μ_{leader}代表 Leader 子图的通道均值，σ_{leader}代表通道标准差，ϵ为数值稳定项。

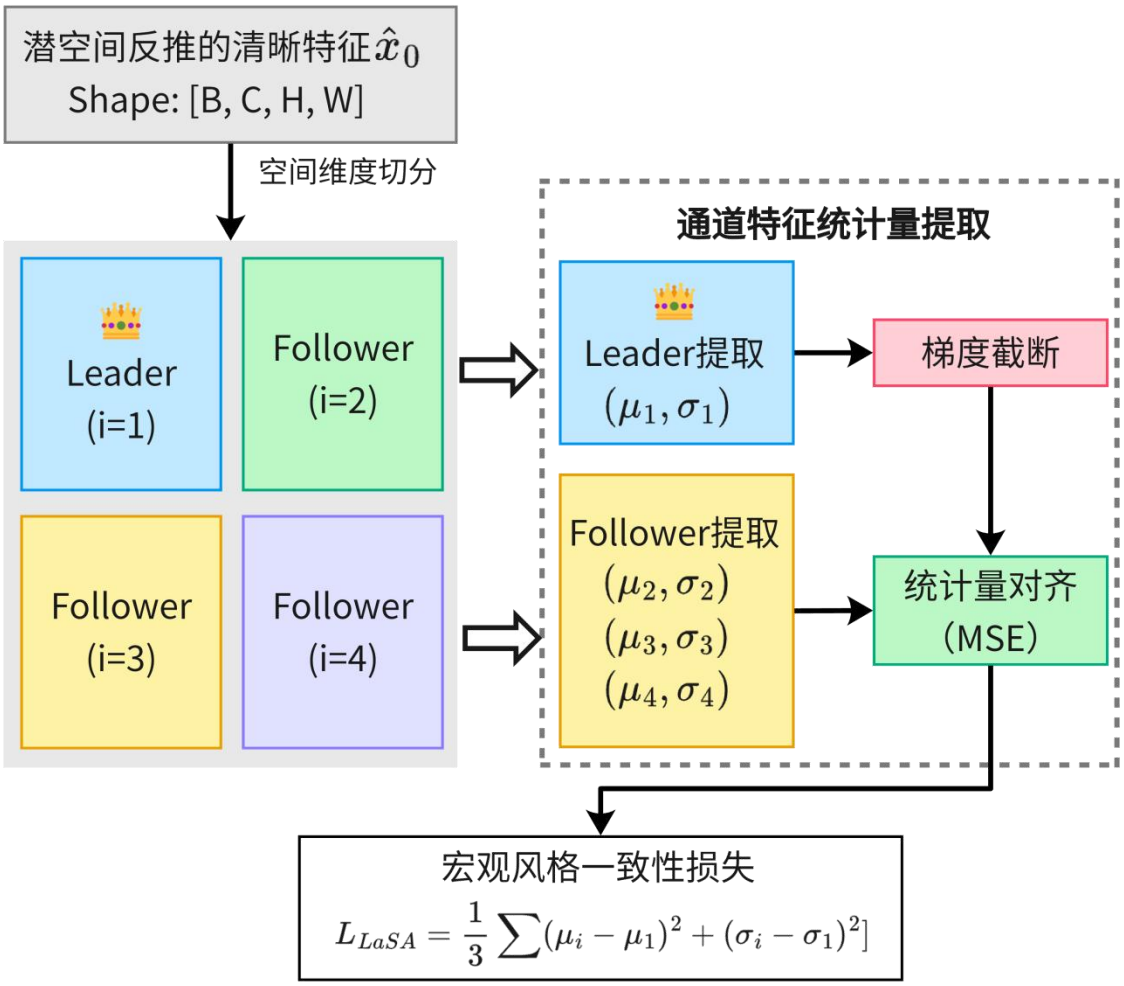

图 4. 5 潜空间 Leader–Follower 统计量对齐机制示意图

为了防止梯度回传至 Leader 本身导致优化不稳定，对 Leader 的统计量执行 detach() 梯度截断操作。随后，对于三个 Follower 子图（$i = 2$，3，4），同样计算其统计量 μ_i与 σ_i，并构建基于均方误差的 LaSA 损失：

$$L_{\mathrm{LaSA}} = \frac{1}{3}\sum_{i=2}^{4}\left[\left(\mu_i - \mu_{\mathrm{leader}}\right)^2 + \left(\sigma_i - \sigma_{\mathrm{leader}}\right)^2\right] \tag{4.5}$$

该损失函数在不破坏车辆几何结构的前提下，直接在潜空间底层强力约束了 Follower 子图在统计量层面向 Leader 对齐。这不仅大幅降低了计算开销，更从算法底层确保了四个子图在最终解码为图像时，能够呈现出高度一致的宏观风格。这一机制

的有效性在第五章的定量实验中得到了充分验证，相较于无约束的 Baseline，本方法在色彩一致性（Histogram Similarity）指标上取得了 55.6%的显著提升。

第四节 基于扩散时间步的动态加权优化

在引入 Grid 内部一致性约束（L_{LaSA}）后，总损失函数被定义为：

$$L_{total} = L_{base} + \lambda L_{LaSA} \tag{4.6}$$

如何科学地设定权重系数λ，是决定模型能否稳定收敛并兼顾“车辆 ID 准确性”与“宏观风格一致性”的关键。本节将结合初步实验现象，深入剖析权重设定的困境，并推导出最终的自适应连续衰减权重策略。

一、固定权重与条件权重的缺陷

在初步实验阶段，本研究尝试了两种常规的权重分配策略，但均引发了严重的训练不稳定或生成崩坏问题。对其失败原因的剖析，揭示了流匹配（Flow Matching）机制中时间步t与特征演化的内在规律。

（一）固定权重

首先，本研究尝试在所有时间步$t \in [0,1]$中使用全局固定的常数权重（即$\lambda = constant$）。实验结果表明，该策略严重妨碍了正常的 LoRA 训练，导致微调后的模型无法准确还原特斯拉 Model Y 的专属特征，甚至出现了与未加 LoRA 的纯 FLUX 基座模型相同的“画错车型”问题。

从流匹配的物理意义来看，这一现象的根源在于极早期阶段（$t \to 1$）的梯度噪声干扰。当$t \to 1$（即纯噪声状态）时，模型输入x_t几乎不包含任何结构信息，此时模型预测的速度场$v_\theta(x_t)$具有极大的不确定性。根据公式：

$$\widehat{x_0} = x_t - t \cdot v_\theta(x_t) \tag{4.7}$$

此时反推得到的清晰原图$\widehat{x_0}$几乎是随机像素的堆叠。若在此时强行施加统计量对齐约

束（L_{LaSA}），会淹没基础去噪损失（L_{base}）原本用于学习车辆几何轮廓与 ID 特征的正确梯度。模型将有限的参数容量耗费在拟合随机噪声的统计量上，最终导致核心实体学习失败。

（二）基于扩散时间步的条件权重

为了规避$t \to 1$ 时的噪声干扰，本研究随后尝试了“时间步条件权重（Step-Conditioned Weight）”策略，即仅在特定时间步$t < 0.3$（模型已进入接近清晰图像的生成后期）时，才以固定权重将L_{style}激活并加入总损失；而在$t \geq 0.3$ 时$\lambda = 0$。

然而，实验结果表明该策略导致了生成崩坏（例如生成的车辆缺失车头、车身结构扭曲等）。这一现象的本质原因是损失函数景观（Loss Landscape）的不连续性引发了“梯度突变（Gradient Shock）”。在深度学习优化（如本研究使用的 AdamW 优化器）中，优化器高度依赖历史梯度的动量（Momentum）来维持更新方向的平滑。在$t \geq 0.3$ 的阶段，模型正专注于通过基础损失（L_{base}）构建车辆的物理几何结构；当t跨越 0.3 的阈值时，统计量对齐损失（L_{LaSA}）突然被激活，总损失函数（L_{total}）瞬间发生剧烈跳变。这种突变产生了一个与原几何构建方向完全不同的巨大梯度向量，瞬间破坏了 AdamW 的动量状态。模型为了迅速降低突然出现的对齐损失，强行扭曲了原本已经初步成型的潜空间特征，最终导致空间几何结构崩坏。

二、自适应衰减权重策略设计

上述两次失败的尝试证明潜空间统计量对齐损失（LaSA Loss）的权重既不能在早期强加，也不能在后期突变。因此，权重λ必须是一个关于时间步t的连续且平滑的单调递减函数。

结合代码工程实践，本研究最终设计了如下基于扩散时间步的自适应衰减权重：

$$\lambda(t) = \alpha \cdot (1.0 - t) \tag{4.8}$$

其中α为基础缩放系数。

生成初期（$t \to 1$）：权重$\lambda(t) \to 0$。模型完全将注意力集中于基础损失（L_{base}）去噪，确保 LoRA 能够精准学习并锁定车辆的几何结构与 ID 特征，解决了固定权重导致的“画错车型”问题。

平滑过渡期（t逐渐减小）：随着t的下降，$\lambda(t)$连续且缓慢地增加。对齐梯度被

平滑地引入优化过程，避免了任何形式的梯度突变，保护了优化器的动量状态，从而避免了结构崩坏（如“缺失车头”）的现象。

生成后期（$t \to 0$）：权重$\lambda(t) \to \alpha$。此时图像的几何结构已高度确定，反推的$\widehat{x}_0$极其可靠。模型在强权重的L_{LaSA} 驱动下，对 2×2 Grid 内部四个子图的宏观风格一致性进行统一。

通过这一动态加权机制，本研究成功化解了多任务学习中的梯度冲突，使得改进后的 FLUX 模型在确保车辆 ID 精准的前提下，实现了图像跨区域宏观风格一致。

第五节 本章小结

本章作为全文的核心技术章节，系统阐述了基于改进 FLUX 模型的多图排版与宏观风格一致性可控生成算法，完整构建了从数据输入到损失优化的轻量级微调（LoRA）技术闭环。

首先，本章详细解析了 In-Context LoRA（IC-LoRA）的排版与上下文隐式学习机制。通过引入 2×2 图像网格物理拼接与高度结构化的联合文本对齐策略，有效激活了 FLUX 底层 DiT 架构的全局自注意力机制，迫使模型在不修改底层代码的前提下，自主学习多子图之间的空间排版逻辑与语义连贯性。

其次，针对传统流匹配（Flow Matching）基础损失仅关注微观逐像素去噪、易导致宏观风格割裂的固有局限，本章创新性地提出了潜空间统计量对齐模块（LaSA）。该模块通过从噪声状态反推潜空间清晰图像$\widehat{x}_0$，并设计 Leader-Follower 机制对齐子图特征的通道统计量（μ, σ），从算法底层直接且高效地保障了生成图像在跨区域的宏观风格上高度统一。

最后，针对引入双损失函数后引发的“车辆 ID 丢失”与“几何结构崩坏”等优化困境，本章深度剖析了扩散时间步t与特征演化规律的内在物理联系，推导并设计了自适应连续衰减的动态加权优化策略，化解了多任务学习中的梯度冲突，确保了优化器动量状态的平滑与模型训练的稳定性。

第五章 实验设置与结果分析

本章的核心任务是构建一套契合广告商业评估逻辑的综合评价体系，并通过多维度的定量指标与定性可视化分析，全面验证所提算法的有效性与工程落地价值。通过严谨的消融实验与基线对比，本章旨在为该自动化生成方案在真实泛营销场景中的商业应用提供坚实的数据支撑。

第一节 实验环境与配置

本研究的所有实验均在配备单块 vGPU-48GB（显存 48GB）的云端 GPU 服务器上完成。选用的基座模型为 FLUX. 1-dev（120 亿（12B）参数）。本研究实验的具体训练参数配置如下：

表 5. 1 实验参数配置

配置项	具体参数	说明
硬件环境	vGPU-48GB × 1	云端 GPU 服务器
基座模型	FLUX. 1-dev	模型参数量约 12B
LoRA 秩（Rank）	16	低秩适应，参数高效
LoRA Alpha	16	Alpha / Rank = 1
批量大小	2（累积 4 次）	等效 Batch Size = 8
优化器	AdamW 8-bit	显存优化
学习率	1e-4	常见学习率
总训练步数	2000	每 400 步保存检查点
梯度检查点	启用	降低显存峰值
EMA 衰减系数	0. 99	平滑权重更新
图像分辨率	(1024, 1024)	网格 Grid 拼接

第二节 改进型 FLUX 模型生成效果定量分析

一、评价指标体系设计

为了客观评估本研究提出的改进型 FLUX 生成框架在汽车广告图像可控生成任务中的实际效果，本节设计了一套综合的定量评价体系，并对三组对照实验进行了系统的量化分析。本研究构建的评价指标体系从“文本可控性”与“多图一致性”两个维度出发，共设计了三类核心指标：

（一）文本把控度评价指标设计

采用 CLIP（Contrastive Language-Image Pre-training）模型计算图像与文本提示词之间的语义相似度，作为衡量模型文本可控性的核心指标。CLIP Score 通过在海量图文对上进行对比学习训练，能够准确量化生成图像与输入提示词之间的语义匹配程度。针对本研究中 2×2 Grid 拼接图像的特殊性，设计了“局部匹配得分”与“全局主题得分”双重 CLIP Score 计算策略。

局部匹配得分（CLIP Score matched）

将 Grid 分割为四个子图，分别与结构化 Prompt 中对应的局部描述（如[IMAGE1]、[IMAGE2]等）进行匹配，计算四个子图的平均 CLIP Score。该指标衡量模型对细粒度文本指令的精准执行能力。具体计算公式为：

$$\text{CLIP Score}_{\text{matched}} = \frac{1}{4}\sum_{i=1}^{4} \text{Sim}_{\text{CLIP}}\,(\text{Image}_i, \text{Prompt}_i) \qquad (5.1)$$

其中，Sim_{CLIP}通过计算图像特征与文本特征在高维语义空间中的余弦相似度得到。

全局主题得分（CLIP Score global）

将四个子图分别与结构化 Prompt 中提取的全局风格描述（[GLOBAL DESCRIPTION]）进行匹配，评估整体主题的一致性。具体计算公式为：

$$\text{CLIP Score}_{\text{global}} = \frac{1}{4}\sum_{i=1}^{4} \text{Sim}_{\text{CLIP}}\,(\text{Image}_i, \text{Prompt}_{\text{global}}) \qquad (5.2)$$

其中，Sim_{CLIP}通过计算图像特征与文本特征在高维语义空间中的余弦相似度得到。

（二）宏观风格一致性评价指标设计

为了量化 Grid 内部四个子图在宏观风格上的统一程度，本研究采用了“风格相似度”与“色彩相似度”两类指标。

风格相似度（CLIP Image Similarity）

提取四个子图的 CLIP 视觉特征（Image Embedding），计算两两之间的余弦相似度。CLIP 作为在大规模数据上训练的多模态模型，其图像编码器能够捕捉高层语义风格特征，相比传统的像素级度量更符合人类对“风格”的感知。计算公式为：

$$\mathrm{CLIP}_{\mathrm{style}} = \frac{2}{n(n-1)} \sum_{i=1}^{n-1} \sum_{j=i+1}^{n} \left(1 - \mathrm{cosine}(\mathrm{f}_i^{\mathrm{CLIP}}, \mathrm{f}_j^{\mathrm{CLIP}})\right) \tag{5.3}$$

其中$n = 4$ 为子图数量，$\mathrm{f}_i^{\mathrm{CLIP}}$为第$i$张子图的 CLIP 特征向量。

色彩相似度（Histogram Similarity）

在 HSV 色彩空间中计算 32×32×32 的三维颜色直方图，通过直方图相关系数来量化子图间的色调、饱和度与亮度分布的一致性。该指标直接反映了本文所提 LaSA 模块对宏观色彩统一的控制效果。

（三）综合评分指标设计

为了给出整体评价，设计加权综合评分：

$$\begin{aligned}\mathrm{Score}_{\mathrm{composite}} = \\ & 0.2 \times \mathrm{CLIP}_{\mathrm{matched}} + 0.2 \times \mathrm{CLIP\ Score}_{\mathrm{global}} \\ & +0.3 \times \mathrm{CLIP}_{\mathrm{style}} + 0.3 \times \mathrm{Histogram}_{\mathrm{similarity}}\end{aligned} \tag{5.4}$$

广告图像的核心价值在于精准传达营销诉求（文本把控度）与保持品牌视觉规范（宏观风格一致性），因此赋予文本把控度评价指标一共 40%权重，宏观风格一致性评价指标一共 60%权重。

二、实验分组设计

为了验证本文提出的 In-Context LoRA 机制与 LaSA 模块的有效性，设计了三组对照实验，每组实验均在相同的测试集（包含第三章定义的八大标签维度和对应结构化 Prompt）上进行推理，每个标签维度使用不同种子推理 3 次，每个实验组最终包含 96 个样本，确保对比的公平性。

表 5.2 实验分组

实验组	说明
实验组 1（Baseline）	原生 FLUX.1-dev 模型，不加载任何 LoRA 权重
实验组 2（IC-LoRA Only）	加载 IC-LoRA 权重，不引入 LaSA 模块
实验组 3（Ours）	完整的改进框架（IC-LoRA + Dynamic LaSA）

三、生成质量定量分析

（一）整体性能对比

各实验组在各项评价指标上的得分见表 5.3，其多维指标对比的雷达图与综合得分柱状图分别如图 5.1 与图 5.2 所示。

表 5.3 实验组各指标得分

实验组	样本数量	局部匹配度得分	全局匹配度得分	风格相似度得分	色彩相似度得分	综合得分
实验组 1（Baseline）	96	0.3271	0.3224	0.8564	0.2899	0.5884
实验组 2（IC-LoRA Only）	96	0.3140	0.3211	0.8761	0.3312	0.6099
实验组 3（Ours）	96	0.3198	0.3265	0.8796	0.4511	0.6615

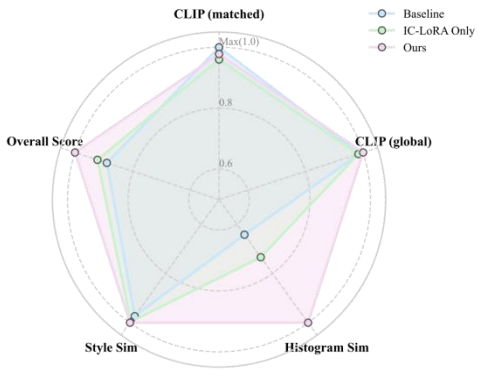

图 5.1 实验组各项得分雷达图

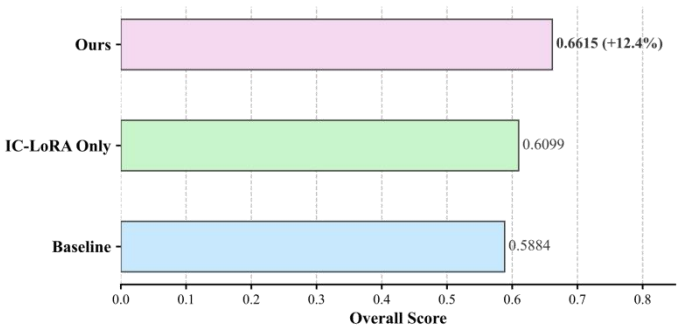

图 5.2 综合评分柱状图

在文本把控度维度，实验组 1（Baseline）在局部文本匹配得分上保持微弱领先。

这一现象符合预期，因为原生 FLUX 模型在预训练阶段高度优化了单图的细粒度指令遵循能力；而在引入 2×2 Grid 拼接后，多子图的复杂空间布局会在一定程度上分散模型对局部细节的注意力。然而，在更宏观的全局主题得分上，实验组 3（Ours）得分反超实验组 1（Baseline）取得最高分。这证明了，In-Context LoRA 通过联合描述（Joint Caption）的训练策略，成功赋予了模型对个性化场景的深刻理解，弥补了基座模型在垂直营销领域的认知短板。

宏观风格一致性控制维度是本文改进算法的核心贡献所在，实验数据展现出了断层式的优势。相比于实验组 1 和实验组 2，实验组 3（Ours）在风格相似度与色彩相似度两项关键指标上均实现了大幅跨越。特别是在衡量宏观色彩与光影统一性的色彩相似度上，实验组 3（Ours）相比实验组 1（Baseline）提升了 55.6%。这一显著的量变直接证明：仅靠 IC-LoRA 的数据隐式约束（实验组 2）不足以彻底解决多图宏观风格割裂问题；而本文提出的 Dynamic LaSA 模块，通过在潜空间底层强制对齐通道统计量，精准且高效地实现了 Grid 内部宏观风格的统一。

在综合评分方面，实验组 3（Ours）以高出实验组 1（Baseline）12.4%的优势夺冠，相比实验组 2（IC-LoRA Only）提升了 8.5%。这一结果充分验证了本文方法在多图生成任务中的系统性优越性。

（二）指标分布与稳定性分析

在实际的商业广告自动化生成中，模型不仅需要“平均表现好”，更需要“生成下限高”（即极低的废片率）。为此，本研究进一步对三组实验在不同测试样本上的标准差（Standard Deviation）进行了统计，如表 5.4 所示。

表 5.4 实验组稳定分指标得分

实验组	全局主题标准差	风格相似度标准差	色彩相似度标准差
实验组 1 (Baseline)	0.0295	0.0421	0.1876
实验组 2 (IC-LoRA Only)	0.0257	0.0358	0.1542
实验组 3 (Ours)	0.0284	0.0312	0.1123

从三组实验的标准差分布可以看出，实验组 3（Ours）在各项一致性指标上展现出

了极强的鲁棒性与稳定性。首先，在风格相似度方面，实验组 3（Ours）的标准差降至最低，优于实验组 1（Baseline）。其次，在最容易发生波动的色彩相似度上，实验组 3（Ours）的标准差相比实验组 1（Baseline）大幅收窄了 40.1%。

这种方差的显著降低揭示了算法机制。在未加约束的 FLUX 模型中，四个子图的生成过程在潜空间中是高度自由的，导致生成的色彩分布具有极大的随机性（高方差）；而本文引入的 Dynamic LaSA 损失在扩散去噪的演化过程中，将三个 Follower 子图的特征分布拉向 Leader 子图，从而极大地压缩了色彩与风格随机漂移的空间。

四、定量分析小结

综合上述定量指标与方差分析，可以得出以下核心结论：

（一）In-Context LoRA 机制的有效性。实验组 2 相比实验组 1 在全局主题与宏观风格相似度上的提升，证明 2×2 Grid 拼接训练策略成功引导模型学习了多图排版的隐式规律与全局语义。

（二）Dynamic LaSA 模块的关键作用。实验组 3（Ours）在色彩一致性上的断层式领先（提升 55.6%），直接验证了第四章提出的 Leader-Follower 统计量对齐机制在控制宏观视觉质感上的核心价值。

（三）整体改进框架的极高鲁棒性。实验组 3（Ours）平均指标最优且各项标准差最低，证明其在本文构建的视觉标签维度上均具有稳定且优异的泛化能力和可靠性。

第三节 改进型 FLUX 模型生成效果定性分析

定量指标虽然能够客观反映模型的平均表现，但在广告视觉资产的商业评估中，人眼主观的“第一印象”与对细节的挑剔往往更为关键。本节通过对三组渐进式消融实验的生成结果进行定性可视化对比，深入剖析各模块在实际生成中的作用机制与潜在缺陷，以验证本文最终提出的 Dynamic LaSA 模块的必要性与优越性。

一、实验组设计

为了全面评估本研究提出的各核心模块，本节采用了与 5.2 定量分析部分相同的三组实验，具体分组见表 5.2。

二、实验组 1（Baseline）分析

在原生 FLUX.1-dev 模型中，模型采用传统的单图微调范式训练。尽管模型学习到

了“特斯拉”这一实体概念，但生成结果展现出了较大缺陷。

（一）车型 ID 特征的漂移。在基线模型的生成样例中，可以明显观察到车辆的几何特征并未忠实还原特斯拉 Model Y。例如，在图 5.3（左）车辆的前脸大灯线条变得锐利且形似其他品牌，在图 5.3（右）车身比例失调，无法锁定专属的产品 ID。

（二）宏观风格的割裂。正如 5.2 节定量数据所示，实验组 1 的色彩一致性极低。在视觉上直观表现为：同一批次生成的四张图像仿佛来自完全不同的拍摄环境。例如，图 5.4（左）中四个子图区域的车辆主体颜色完全不一致；图 5.4（右）中背景的色彩、内在逻辑分布毫无关联，彻底破坏了广告物料应有的成套商业质感。

（三）无法形成有效的成套排版。基线模型无法完全正确理解联合描述中的排版指令。生成的图像未能形成规整的 2 × 2 网格排版（如图 5.5）。

图 5.3 实验组 1 生成样例

图 5.4 实验组 1 生成样例

图 5.5 实验组 1 生成样例

三、实验组 2（IC-LoRA only）分析

引入 In-Context LoRA 的高质量训练数据对（2 × 2 Grid 图像和结构化联合描述）后，模型生成质量出现了较大提升。

（一）车型 ID 锁定。通过在单个 Batch 内强制学习多视角的 Token 关联，模型成功建立了跨子图的“车辆实体一致性”约束。在测试样例中，车辆的前灯、车身线条等细节特征保持了较高的一致性，解决了实验组 1 中的“车型混淆”问题。

（二）排版逻辑的智能涌现。如图 5.6 所示，模型自主学习到了 2 × 2 Grid 排版范式，极大提升了成套物料的叙事完整性。

这种各子图区域宏观风格差异表明，仅靠上下文隐式学习，无法强制约束模型在生成过程中对各子图区域宏观风格一致性的把控。

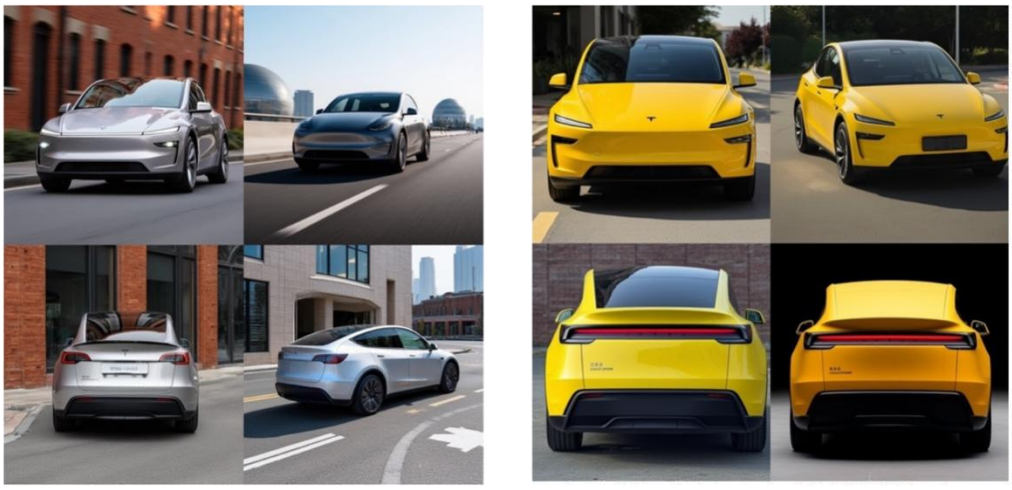

图 5.6 实验组 2 生成样例

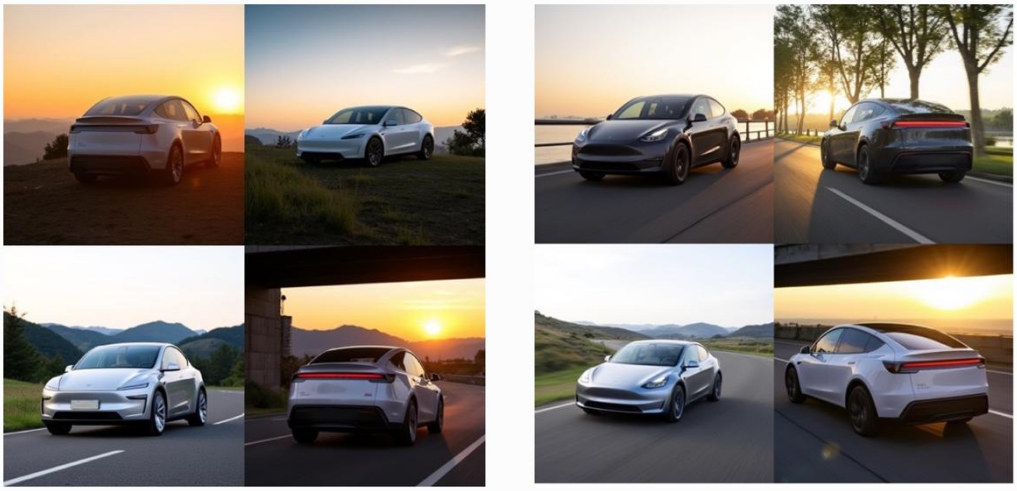

图 5.7 实验组 2 生成样例

四、实验组 3（Ours）分析

本研究最终采用 Dynamic LaSA 策略，在各营销标签下均展现出了极高的生成质量。

（一）“车型 ID”稳定与空间结构的完整性。在测试样例中，车辆的车灯形状、前脸轮廓以及溜背曲线均得到了高精度的还原。更为重要的是，四个子图区域内的车辆均呈现出完整的物理几何结构，无任何缺失车头、前脸畸变等崩坏现象，证明动态权重成功避免了梯度突变对空间构建的破坏。

（二）光影色调统一。在图 5.9（左）“改色潮流”样例中，四个子图区域不仅车辆 ID 一致，而且均呈现出一致的明亮暖调与高光反射，视觉上极具统一感；在图 5.9（右）“都市霓虹”样例中，四个子图区域均精准呈现了夜晚城市灯光的氛围，其色彩饱和度与明暗对比度均保持了高度的视觉连贯性；在图 5.10“黑武士风格”的两个样例中，子图区域均维持了极暗的背景基调，通过一致的边缘轮廓光来勾勒车辆主体。

（三）宏观风格一致。在图 5.11“户外露营”两组样例中，各个子图共享了一套统一的“森系”大地色盘，阳光穿透树叶洒在车身上的斑驳光影在四个视角中呈现出一致的柔和质感；在图 5.12（左）“动态模糊”样例中，四个子图的背景均呈现出一致且强度均匀的运动模糊效果，而车辆主体则保持清晰锐利，传达了统一的速度感与操控性能；在图 5.12（右）“日落公路”样例中，整个 2×2 网格图被统一的黄金时刻暖黄色调所笼罩，四个视角的逆光光晕与长阴影在视觉逻辑上高度自洽，避免了实验组 2 中出现的“时空错乱”问题。

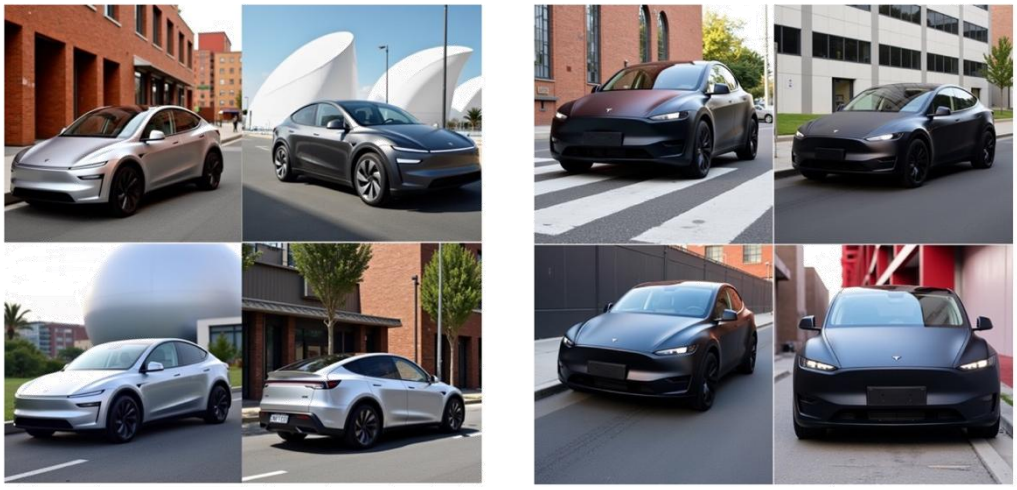

图 5. 8 实验组 3 生成样例

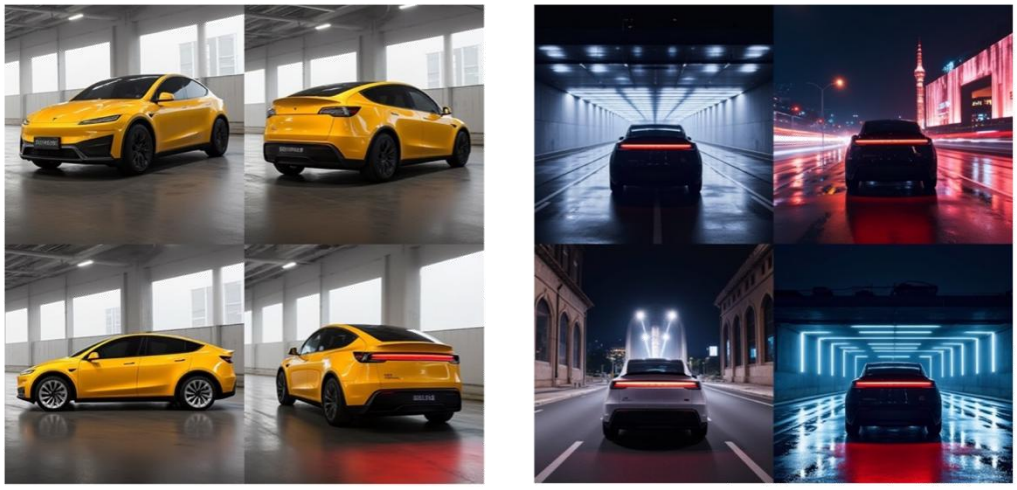

图 5. 9 实验组 3 生成样例

图 5. 10 实验组 3 生成样例

图 5. 11 实验组 3 生成样例

图 5. 12 实验组 3 生成样例

动态衰减权重的成功，验证了本文在 4. 4. 2 节中提出的核心洞察。在流匹配的连续时间演化中，损失函数的权重必须与特征的确定性同步变化。在 $t \to 1$ 时完全屏蔽风格梯度，保护图像内容结构学习；在 t 下降过程中平滑引入风格约束，维护优化器稳定；在 $t \to 0$ 时强力统一宏观风格。这一基于时间步加权的动态损失函数是本研究在算法设计上的核心贡献。

第四节 损失函数权重策略的消融探究

在前文的 5. 2 与 5. 3 节中，本研究已经充分验证了本文最终提出的“IC-LoRA +

Dynamic LaSA”方法在多图生成质量与宏观风格一致性上的显著优势。然而，正如本文在 4.4 节理论推导中所指出的，双损失函数（基础损失与 LaSA 损失）的权重分配是决定模型能否稳定收敛的关键。为了进一步通过实验数据佐证 4.4 节的理论推导，本节设计了针对权重策略的消融实验。我们将对比分析 2 种失败的权重策略：“全局固定权重（Fixed Weight）”、“时间步条件权重（Step-Conditioned Weight）”，通过两次失败实验揭示不当的权重策略如何导致“车辆 ID 丢失”或“几何结构崩坏”。

表 5.5 消融实验分组

实验组	说明
失败组 1	引入 LaSA 模块，在所有时间步使用固定权重
失败组 2	引入 LaSA 模块，在$t < 0.3$ 时以固定权重激活

一、失败尝试 1：固定权重

本研究首次尝试引入 LaSA 模块，并采用“全局固定权重策略”，在所有时间步使用固定权重（$\lambda = 0.5$）。如图 5.13 所示，该策略导致了模型性能退化。首先，2×2 的网格排版结构被打破；其次，部分画面中的车辆失去了特斯拉的品牌特征。这直观地证明了在纯噪声阶段（$t \to 1$）强加风格约束，会破坏模型对几何结构和实体 ID 的构建能力。

图 5.13 失败组 1 生成样例

结合 4.4 节的理论分析，这一现象的根源在于：在流匹配的极早期阶段（$t \to 1$），模型输入近乎纯噪声，反推的$\widehat{x}_0$完全不可靠。此时固定权重的 LaSA 损失强行对齐四个子图的随机统计量，产生了巨大的噪声梯度。这些无意义的对齐梯度在反向传播时淹没了基础损失中用于去噪（学习车辆 ID、几何结构）的正确梯度，导致 LoRA 权重被错误更新，最终丧失了对车辆实体的准确表达能力。

二、失败尝试 2：基于扩散时间步的条件权重

为了规避早期噪声干扰，本研究第二次尝试采用“时间步条件权重策略”。仅在$t < 0.3$（接近清晰图像阶段）时激活固定权重的 LaSA 损失（$\lambda = 1.0$），在$t \geq 0.3$时则完全关闭（$\lambda = 0$）。如图 5.14 所示，该策略引发了更为诡异的局部结构崩坏现象。在“都市霓虹（City）”与“动态模糊（Motion）”标签下，可以清晰地观察到“双车尾”现象；在“户外露营（forest）”标签下，出现了“无头车”畸变。

图 5.14 失败组 2 生成样例

这一现象印证了 4.4 节的理论推测：突然引入的 LaSA 损失会导致梯度方向的剧烈突变，进而破坏优化器的动量状态。具体而言，在$t = 0.3$ 的阈值处，总损失函数瞬间从基础损失（L_{base}）跳变为$L_{base} + L_{LaSA}$，这产生了一个与原几何构建方向完全不同的巨大梯度向量。模型为了迅速降低突然出现的对齐损失，强行扭曲了已经初步成型的潜空间特征，导致正在生成的车头结构被强制抹除或融合，最终形成空间几何的彻底崩坏。

第五节 本章小结

本章围绕汽车广告图像的可控生成任务，对本文提出的“基于改进 FLUX 的多图

排版与宏观风格一致性生成框架”进行了全面且系统的实验验证与机制剖析。

首先，本章详细交代了基于 FLUX. 1-dev 基座模型的微调实验环境与超参数配置，并针对多图生成任务的特殊性，创新性地构建了包含“文本把控度（局部/全局 CLIP Score）”与“宏观风格一致性（CLIP 风格相似度、色彩直方图相似度）”的多维定量评价体系。

其次，通过严密的定量与定性对比分析，充分证实了本文核心算法的卓越性能。实验数据与可视化结果表明：单独的 In-Context LoRA（IC-LoRA）机制虽能有效锁定车辆 ID 特征并诱导模型涌现出 2×2 Grid 的智能排版能力，但在宏观风格的统一上仍存在软肋；而完整引入“IC-LoRA”和“基于扩散时间步动态加权的潜空间统计量对齐（Dynamic LaSA）模块”后，模型在色彩直方图相似度上较基线模型大幅提升了 55. 6%，综合评分提升 12. 4%。在视觉呈现上，该方法解决了多图生成中常见的“宏观风格不一致”（如光影割裂、色调不一、各子图区域场景缺乏内在逻辑）的痛点，实现了极高质感的成套广告物料输出。

最后，本章针对损失函数的权重分配策略开展了深度的消融探究。通过实验现象剖析了“全局固定权重策略”导致的车辆 ID 遗忘，以及“时间步条件权重策略”引发的局部几何结构崩坏，利用消融实验结果佐证了第四章关于“流匹配时间步与特征演化规律”的理论推导。这一探究强有力地证明了本文所设计的“自适应连续衰减权重策略”在化解多任务梯度冲突、保障模型稳定中的合理性。

综上，本章的实验结果不仅验证了各项算法创新模块的有效性，更成功打通了从理论推导到工程落地的闭环，为汽车及泛商业领域的自动化视觉资产生成提供了一套高效、稳定且可控的全新解决方案。

第六章 总结与展望

第一节 研究总结

本文以特斯拉 Model Y 为研究对象，针对计算广告领域中汽车视觉物料生产面临的“成本高、周期长、一致性难控”三大痛点，提出了一种“数据洞察驱动+底层算法约束”的全新生成范式。研究在跨模态数据工程与底层生成算法修改两个层面取得了系统性的创新突破。

在跨模态数据工程层面，本文打通了从“社媒舆情挖掘”到“高质量训练数据集构建”的全链路。通过定向采集小红书平台 8117 条帖文及 22400 张原始图片，利用 TF-IDF 算法结合多模态大模型（CLIP、Qwen-VL）挖掘并清洗出 6559 张高质量底图，并在此基础上构建了包含“黑武士风格”、“纯净美学”、“金属质感”、“改色潮流”、“都市霓虹”、“户外露营”、“日落公路”、“动态模糊”八大维度的视觉标签体系并沉淀出一套具有跨行业泛化价值的自动化标签提取范式。这一标签体系为后续模型的语义可控生成提供了极具商业逻辑的数据先验。进一步地，通过 YOLOv8 智能居中裁切、CLIP 特征相似度网格拼接以及 Qwen-VL 多模态大模型进行联合描述（Joint Captioning）打标等工程创新，最终构建了 113 组高质量的多模态广告训练数据集。

在底层生成算法层面，本文针对现有扩散模型在生成成套图像时存在的“生成主体不一致”与“宏观风格易割裂”两大瓶颈，提出了基于改进 FLUX 的可控生成方法。一方面，引入了 In-Context LoRA（IC-LoRA）拼接训练策略，通过在单个 Batch 内强制模型学习 2×2 Grid 的上下文隐式关联，成功解决了多视角图像的排版控制与车辆 ID 精准还原问题。另一方面，针对基础流匹配损失（Flow Matching Loss）关注微观像素去噪而忽略宏观风格统一的局限，本文受自适应实例归一化（AdaIN）思想启发，创新性地提出了潜空间统计量对齐模块（LaSA），并针对多任务梯度冲突，设计了基于扩散时间步t的动态衰减权重策略（Dynamic LaSA）。通过深度的消融实验验证了

该策略能够成功化解多任务学习中的梯度冲突，实现了平滑优化范式。实验结果表明，改进后的框架在保证车辆 ID 精准与空间结构完整的前提下，使色彩一致性指标相较于 Baseline（原生 FLUX. 1-dev 模型）提升了 55. 6%。

第二节 商业落地价值与行业赋能意义

本研究提出的“基于自动化标签与改进 FLUX 模型的汽车广告图文生成框架（IC-LoRA + Dynamic LaSA）”，不仅在计算机视觉与多模态生成的学术指标上取得了突破，更针对当前广告公司与品牌方的核心痛点，展现出了实际的商业落地价值。

其一是重构美术生产管线，实现指数级的“降本增效”。在传统的汽车广告物料生产管线中，拍摄一套包含“日落公路”、“户外露营”等多场景的成套视觉资产，需要经历漫长的堪景、场地租赁、专业摄影团队调度以及繁重的后期精修。单套物料的制作周期往往长达数周，成本动辄数十万至上百万人民币。而本研究提出的自动化生成方案，打破了物理拍摄的限制。广告优化师只需输入前文构建的自动化标签（如“黑武士风格+户外露营”），系统即可在几分钟内，以极低的算力边缘成本，生成一套具备极高商业可用性的多视角排版图像。这种从“数周/数十万”到“数分钟/几分钱”的跨越，为广告代理商节省了极其可观的制作预算与时间成本，使得创意的敏捷迭代成为可能。

其二是保护品牌视觉资产，攻克 AIGC 商用痛点。当前，虽然 Midjourney、Stable Diffusion 等基础大模型已广泛应用于广告业，但其生成的图像往往存在严重的“抽卡”随机性。在需要生成“九宫格”或“成套海报”时，各图像之间的主体一致性、色彩调性、光影质感往往大相径庭，这严重破坏了整合营销传播中“品牌视觉统一性”的要求。本研究在第四章创新性引入的 Dynamic LaSA（潜空间统计量对齐）模块，从底层算法逻辑上强制约束了生成图像的“宏观风格高度一致”。这一技术突破使得 AI 生成的成套物料不再是割裂的单图拼凑，而是如同出自同一位资深摄影师之手。它直接解决了 AIGC 在专业广告商用中“难以控制品牌调性”的痛点，为品牌视觉资产的安全与规范提供了算法级保障。

其三是赋能“生成式 DCO”，开启千人千面的场景营销。传统的动态创意优化（DCO）受限于素材库的容量，只能进行生硬的元素拼接（如“抠图车”+“库存背

景”）。本研究通过“八大场景标签”的构建实现了“生成式 DCO”。在实际投放中，系统可以根据用户的实时标签（如：周末、喜爱户外、女性），高效地生成一套该用户专属的“女性驾驶 Model Y 在周末露营”的高质量融合海报。这种将“场景营销理论”与“AIGC 实时生成技术”完美闭环的落地能力，将极大地提升汽车广告的点击率（CTR）与转化率（CVR），为计算广告迈向全面智能化提供了极具价值的工业级解决方案。

第三节 局限性与未来展望

尽管本研究在技术创新与商业应用上取得了显著成果，但仍存在若干局限性，并为未来研究留下了广阔的探索空间。

一、当前方法的局限性

（一）细节生成的瑕疵

当前方法在生成车辆主体结构、光影氛围等宏观特征时表现出色，但在极小细节（如车牌号文字生成、复杂的物理遮挡关系）的处理上仍存在偶发性瑕疵。例如，当生成场景涉及多层次的前后景遮挡时，模型偶尔会出现遮挡边界的模糊或物理关系的不合理。这主要是因为基础的扩散模型在潜空间中进行去噪，对像素级别的精细几何约束能力有限。

（二）训练数据的时效性约束

由于 FLUX 基座模型发布于 2024 年 8 月，彼时特斯拉 Model Y 的 2025 款新车型尚未上市，因此 FLUX. 1-Dev 模型的原始训练数据集中缺少新款车型的视觉样本。虽然引入 LoRA 微调能够在一定程度上使模型生成新款外观的图像，但由于基座模型缺乏真实的新款数据作为监督信号，无法 100%保证生成结果严格符合 2025 款的专属特征（如全新的灯带式前脸灯组设计）。这一局限性凸显了生成式 AI 在快速迭代的垂直领域应用中，对训练数据实时更新的依赖。

二、未来研究方向

（一）引入多模态空间结构约束机制

为了进一步提升细节生成的精准性与可控性，未来研究可考虑引入 ControlNet 等显式的空间结构控制模块。通过输入车辆的深度图（Depth Map）、边缘图（Canny

Edge）或姿态骨架（Pose Skeleton），能够对生成过程施加更严格的几何约束，精准指定车辆的朝向、视角与空间位置。这种“文本语义+空间结构”的双重控制机制，有望彻底解决物理遮挡关系与极小细节的生成问题。

（二）扩展至视频生成领域

静态图像生成已取得突破，未来更具商业价值的方向是将该框架扩展至视频生成（Video Generation）领域。汽车广告对动态视频内容（如车辆在山路疾驰、镜头环绕车身旋转等）有着极强的需求。可以基于本文提出的 IC-LoRA 与 LaSA 机制，进一步研究如何在时间维度上保持视频帧间的车辆 ID 一致性与光影连贯性。结合最新的视频扩散模型（如 Sora），有望构建从“静态海报”到“动态视频广告”的全流程自动化生成系统。

（三）构建持续学习的数据更新机制

针对训练数据时效性问题，未来可探索构建一种轻量级的持续学习（Continual Learning）框架。当新款车型上市后，仅需采集少量新款数据（如 50—100 张），通过增量微调的方式快速更新模型，避免从头重新训练的巨大成本。同时，可结合主动学习（Active Learning）策略，智能筛选最具代表性的新样本进行标注与训练，进一步降低数据工程的人工成本。

综上所述，本研究不仅在学术上推动了扩散模型在多图一致性生成领域的理论进展，更在工程上为计算广告行业提供了一套完整的、可落地的自动化解决方案。未来随着算法的持续优化与应用场景的不断拓展，生成式 AI 必将在汽车营销乃至更广泛的商业领域释放出更加巨大的商业价值与社会价值。

参考文献

[1] 中国传媒大学广告与品牌学院. 新营销 6.0：AI 营销时代[R]. 北京：中国传媒大学，2026.

[2] 长城汽车股份有限公司. 哈弗 HAVAL 品牌识别规范手册[R]. 保定：长城汽车股份有限公司，2023.

[3] 王宇飞. AI 赋能广告视觉创意与情感共鸣的案例研究[J]. 当代教育与艺术，2026，2(3)：169-173.

[4] 汽车之家. 2025 年 SUV 销量 TOP10：特斯拉 Model Y 卫冕冠军[R/OL]. 北京：汽车之家，2026-01-13.

[5] Peebles W，Xie S. Scalable diffusion models with transformers[C]//Proceedings of the IEEE/CVF International Conference on Computer Vision. 2023：4195-4205.（arXiv：2212.09748）

[6] Black Forest Labs，Batifol S，Blattmann A，et al. FLUX.1 Kontext：Flow matching for in-context image generation and editing in latent space[J]. arXiv preprint arXiv:2506.15742，2025.

[7] LIPMAN Y，CHEN R T Q，BEN-HAIM E，et al. Flow network matching[J]. arXiv preprint arXiv:2210.02747，2022.

[8] Hu E J，Shen Y，Wallis P，et al. LoRA：Low-rank adaptation of large language models[J]. arXiv preprint arXiv:2106.09685，2021.

[9] Huang L，Wang W，Wu Z F，et al. In-Context LoRA for diffusion transformers[J]. arXiv preprint arXiv:2410.23775，2024.

[10] Huang X，Belongie S. Arbitrary style transfer in real-time with adaptive instance normalization[C]//Proceedings of the IEEE International Conference on Computer Vision. 2017：1501-1510.（arXiv：1703.06868）

[11] Rombach R，et al. Fine color guidance in diffusion models and its application to compression[EB/OL]. arXiv preprint arXiv:2404.06865，2024.

[12] Kim J，et al. Style Injection in Diffusion：A Training-free Approach for Image Stylization[EB/OL]. arXiv preprint arXiv:2312.09008，2024.

[13]Arias G, Solà A, Armengod M, et al. Color encoding in Latent Space of Stable Diffusion Models[EB/OL]. arXiv preprint arXiv:2512.09477, 2025.

[14]Morita R, Frolov S, Moser B B, et al. TKG-DM: Training-free Chroma Key Content Generation Diffusion Model[EB/OL]. arXiv preprint arXiv:2411.15580, 2024.

[15]Leng X, Singh J, Hou Y, et al. REPA-E: Unlocking VAE for End-to-End Tuning with Latent Diffusion Transformers[EB/OL]. arXiv preprint arXiv:2504.10483, 2025.

[16]Pan J, et al. CLPFusion: A Latent Diffusion Model Framework for Realistic Chinese Landscape Painting Style Transfer[J]. Computer Animation and Virtual Worlds, 2025.

[17]Radford A, Kim J W, Hallacy C, et al. Learning transferable visual models from natural language supervision[C]//International Conference on Machine Learning. PMLR, 2021: 8748-8763. (arXiv: 2103.00020)

[18]SALTON G, BUCKLEY C. Term-weighting approaches in automatic text retrieval[J]. Information processing & management, 1988, 24(5): 513-523.

[19]Reis D, Kupec J, Hong J, et al. Real-time flying object detection with YOLOv8[J]. arXiv preprint arXiv:2305.09972, 2023.

[20]Bai J, Bai S, Yang S, et al. Qwen-VL: A frontier large vision-language model with versatile abilities[J]. arXiv preprint arXiv:2308.12966, 2023.

[21]Kingma D P, Welling M. Auto-encoding variational bayes[C]//International Conference on Learning Representations, 2014.

[22]康伟.探究李宁品牌视觉识别系统中VI基础设计元素与“国潮”的再融合[D].南昌大学,2025.DOI:10.27232/d.cnki.gnchu.2025.005353.

[23]卫梦瑶,孔霞,刘静.浅谈品牌叙事视角下视觉符号系统的构建策略——以“茶颜悦色”品牌为例[J].艺术设计学刊,2025,(04):37-39.

[24]林星辰.茶叶品牌社交媒体营销中的视觉传播策略[J].福建茶叶,2026,48(01):68-70.

[25]张钦裕.汽车体验式营销场景的构建与消费者购买决策影响机制研究[J].汽车与驾

驶维修(维修版), 2025, (10) : 45-47.
[26]刘婉霞. 汽车营销的数字化跃迁：基于触点整合、场景叙事、沉浸体验与社群运营的四维策略模型[J]. 时代汽车, 2026, (05) : 142-144.
[27]小红书. 2025 年车生活场景白皮书[R]. 上海 : 小红书科技有限公司, 2025.
[28]北京嘉利智联营销管理股份有限公司. 新能源车行业营销趋势洞察及展望：2024-2028 深度报告[R/OL]. 北京 : 中国国际公共关系协会, 2026.

致谢

当论文的最后一个句号落下，回首这四年的本科时光，心中满是感慨与感恩。这篇论文的完成，离不开许多人的指导、帮助与陪伴，在此我想向他们表达最诚挚的谢意。

首先，我要衷心感谢王薇老师、左然老师。从选题方向的确定到研究方法的选择，从技术路线的反复推敲到论文写作的逐字打磨，导师始终以严谨的学术态度和耐心的指导精神引领着我。每当研究陷入瓶颈时，导师总能以独到的视角为我指点迷津；每当我对实验结果感到困惑时，导师的鼓励让我重新找到前行的方向。导师不仅教会了我如何做研究，更教会了我如何以系统性的思维去拆解和解决问题，这种治学的态度与方法将令我受益终身。

感谢中国传媒大学广告学院和数智学院的各位老师，是你们在课堂上传授的专业知识与前沿视野，为本研究奠定了坚实的理论基础。感谢答辩委员会各位老师在百忙之中审阅本文，你们的宝贵意见将使本研究更加完善。

感谢我的家人。你们始终无条件地支持着我的每一个选择，在我焦虑迷茫时给予我最温暖的依靠。你们的理解与包容，是我不断前行的最大动力。

感谢这个伟大的 AI 时代。正是生成式人工智能技术的蓬勃发展，才让本研究所探索的内容成为可能。从扩散模型到 In-Context Learning，从 TF-IDF 到多模态大模型，每一项技术的突破都在拓展着创意生产的边界。本研究既是对这一技术浪潮的一次积极响应，也是对“AI 如何真正服务于垂直商业场景”这一问题的一次深入思考。

四年光阴如白驹过隙。从这里出发，我将带着在中传学到的一切，继续在未来的道路上探索前行。

未来可期，与诸君共勉。